

Guide 2

Exercicio 1


Uma Variável Aleatória é uma função que mapeia os resultados do nosso espaço de amostragem (as faces do dado que calham na vida real) para a reta real (números).

- **Tipo de Variável:** Como os valores que um dado pode assumir são finitos (neste caso, os números de 1 a 6), estamos perante uma Variável Aleatória Discreta.


A função massa de probabilidade define qual é a probabilidade exata associada a cada um dos valores que a variável pode assumir, ou seja,

$$p_X(x_i) = P(X = x_i).$$

```
xx = 1:6;  
yy = (1/6) * ones(size(xx));  
stem(xx,yy)  
title("1(a)")  
ylabel("Prob. mass function of x")  
xlabel("x")
```



```
xx = 0:7;  
base = (1/6) * ones(size(xx));  
yy = cumsum(base);  
stairs(xx,yy)  
title("1(b)")  
ylabel("Cumulative distribution function of x")  
xlabel("x")
```



Exercicio 2

a)

O espaço de amostragem é o conjunto de todos os resultados possíveis de uma experiência aleatória. Um "evento elementar" é o resultado mais básico e indivisível dessa experiência.

Nº total de notas = 100

A probabilidade de tirar uma nota específica é 1 em 100

prob = 1/100

b)

X é capaz de ter estes valores {5, 10, 100}, sendo isto o espaço de amostragem.

Se $X = 5$ a probabilidade de sair uma nota com valor '5' é 9 em 100.

Ou seja, $90/100 = 0.9$

Se $X = 10$ a probabilidade de sair uma nota com valor '10' é 9 em 100.

Ou seja, $9/100 = 0.09$

Se $X = 100$ a probabilidade de sair uma nota com valor '100' é 1 em 100.

Ou seja, $1/100 = 0.01$

c)

```
% Adicionamos um valor extra (ex: 120) para a linha do gráfico não acabar no 100
x = [5 10 100 120];
```

```

% A probabilidade do valor extra é 0, para não alterar a soma cumulativa!
px = [0.9 0.09 0.01 0];


% Cálculo da CDF
Fx = cumsum(px);

% Desenhar o gráfico
stairs(x, Fx)

% Forçar o eixo do x a mostrar apenas os números do teu espaço de amostragem
xticks([5 10 100])

% Limite no eixo dos yy
ylim([0 1.1])

```



Exercicio 3

a) Estimar a PMF por simulação

Espaço de amostragem de X (em 4 lançamentos quais as possibilidades de ver cara): $\{0, 1, 2, 3, 4\}$

```

% Num de experiencias
N = 10e5;
X = 0:4;


lancamentos = randi([0 1], N, 4);
soma = sum(lancamentos, 2);
Px = zeros(1, length(X));
for i = 1:length(X)

    casos_fav = sum(soma == X(i));
    Px(i) = casos_fav / N;

end

```

```
stem(X, Px)
```



b)

Valor esperado / Média

Calcula-se somando todos os valores possíveis do teu espaço de amostragem (x_i), mas ponderando cada um pela sua probabilidade de ocorrer ($p_X(x_i)$). A fórmula matemática é:

$$E[X] = \sum (x_i \cdot p_X(x_i))$$

```
% X e Px foram calculados na alinea a)
```

```
media = sum(X .* Px)
```

```
media =  
1.9986
```

Variância

A variância diz-nos o quão "espalhados" estão os resultados à volta da média. A forma mais eficiente de a calcular usando probabilidades é com a fórmula:

$$Var(X) = E[X^2] - (E[X])^2$$

$E[X^2]$ calcula-se exatamente da mesma forma que o Valor Esperado, mas eleva-se todos os valores do espaço de amostragem ao quadrado:

$$E[X^2] = \sum (x_i^2 \cdot p_X(x_i))$$

```
% X e Px foram calculados na alinea a)
```

```
x2 = X .^2;
```

```
EX2 = sum(x2 .* Px);
```

```
varX = EX2 - media^2
```

```
varX =  
1.0013
```

Desvio Padrão

O **Desvio Padrão** é simplesmente a raiz quadrada da variância.

```
desvio = sqrt(varX)
```

```
desvio =  
1.0007
```

c)

Pequeno resumo antes da resposta:

Distribuições Discretas

(Usadas quando o resultado é um número inteiro, ou seja, algo que se pode "contar", como número de tentativas, de sucessos, etc.)

- **Bernoulli:** Modela uma única experiência básica que tem apenas dois resultados possíveis: "sucesso" (assume o valor 1) ou "fracasso" (assume o valor 0).
- *Parâmetro:* p (probabilidade de sucesso).
- **Binomial:** Modela o número total de sucessos que ocorrem ao fim de n experiências de Bernoulli independentes.
- *Parâmetros:* n (número total de experiências) e p (probabilidade de sucesso em cada uma).
- **Geométrica:** Modela o número de vezes que precisas de repetir uma experiência de Bernoulli até conseguires obter o *primeiro* sucesso.
- *Parâmetro:* p (probabilidade de sucesso).
- **Poisson:** Foca-se no número de ocorrências num determinado intervalo de tempo contínuo ou numa região do espaço. **Não tem** um número fixo de experiências (n), sendo muito útil para modelar a chegada de clientes a um banco ou de mensagens numa rede. Pode também ser usada para aproximar a distribuição Binomial quando o n é muito grande e o p é muito pequeno.
- *Parâmetro:* \lambda (taxa ou valor médio de ocorrências).

Distribuições Contínuas

(Usadas quando a variável pode assumir qualquer valor dentro de um intervalo da reta real, ou seja, coisas que se "medem", como tempo, peso, altura, etc.)

- **Uniforme:** Usada quando todos os valores dentro de um intervalo [a, b] têm exatamente a mesma probabilidade de ocorrer (a densidade é constante).
- *Parâmetros:* a (limite inferior) e b (limite superior).

- **Normal (ou Gaussiana):** É a famosa curva em forma de "sino", simétrica em torno da média. Adequase a muitas características da natureza e humanas (altura, peso, testes de inteligência) e surge quando vários efeitos independentes se acumulam.
- **Parâmetros:** μ ou μ (média) e σ^2 (variância).
- **Exponencial:** Modela frequentemente tempos de espera, como o tempo até um computador avariar ou o tempo entre a chegada de utentes a um hospital. Tem uma propriedade muito particular de "ausência de memória", ou seja, o facto de um sistema já estar a funcionar há 100 horas não altera a probabilidade de ele falhar nas próximas 2 horas.
- **Parâmetro:** λ (taxa de ocorrência).

Outras Distribuições Empíricas

(Identificadas a partir da observação de dados reais)

- **Lei de Benford:** "Lei dos Primeiros Dígitos", indica que em dados reais (como impostos ou contabilidade), o dígito 1 aparece como primeiro dígito com muito mais frequência (quase 30%) do que os restantes. É muito usada para detetar fraudes.
- **Lei de Zipf:** Relaciona a dimensão ou frequência dos elementos numa lista com a sua ordem de importância. Por exemplo, modela a frequência de palavras num texto (a palavra mais comum aparece o dobro das vezes da 2ª mais comum, etc.).

As características físicas da experiência com as moedas:

1. Número fixo de tentativas ou repetições ($n = 4$ lançamentos).
2. Cada tentativa é independente das outras (o resultado de uma moeda não afeta a outra).
3. Cada tentativa tem apenas dois resultados possíveis (cara ou coroa).
4. A probabilidade de sucesso (p) é constante em todas as tentativas (como a moeda é equilibrada, $p = 0.5$).
5. A nossa variável aleatória X está a contar o **número total de sucessos** nestas n tentativas.

Com base nas distribuições nomeadas acima, para esta experiência a distribuição correta será a Binomial.

A distribuição Binomial é dada por:

$$p_X(k) = \binom{n}{k} p^k (1 - p)^{n-k}$$

A expressão final fica:

$$p_X(x) = \binom{4}{x} 0.5^x (1 - 0.5)^{4-x}$$

Como $1 - 0.5 = 0.5$, pode-se simplificar para:

$$p_X(x) = \binom{4}{x} 0.5^4$$

d)

```
X = 0:4; % Espaço de amostragem
n = 4;   % Número de lançamentos
p = 0.5; % Probabilidade de sucesso

% Calcula a probabilidade teórica exata para o 0, 1, 2, 3 e 4
Px_teorico = binopdf(X, n, p);


% alinea a) (azul)
stem(X, Px, 'LineWidth', 2)

hold on;

% O 'r*' vermelho (red) e um asterisco
stem(X, Px_teorico, 'r*', 'LineWidth', 1)

hold off;

legend('Simulação a)', 'Teórico (Binomial)')
xlabel('Número de Caras')
ylabel('Probabilidade')
title('Comparação da PMF: Simulação vs Teoria')
```



e)

Com base na TP4

- **Média (Valor Esperado):** $E[X] = n * p$
- **Variância:** $Var(X) = n * p * (1 - p)$

```
% n e p definidos na alinea d)
```

```
media_teorica = n * p
```

```
media_teorica =  
2
```

```
var_teorica = n * p * (1 - p)
```

```
var_teorica =  
1
```

f)

i)

```
fi = sum(Px_teorico(3:5))
```

```
fi =  
0.6875
```

ii)

```
fii = sum(Px_teorico(1:2))
```

```
fii =  
0.3125
```

iii)

```
fiii = sum(Px_teorico(2:4))
```

```
fiii =  
0.8750
```

Exercicio 4

Número de peças (tentativas): $n = 5$

Probabilidade de defeito (sucesso da variável): $p = 0.30$

Espaço de amostragem de $X = \{0, 1, 2, 3, 4, 5\}$

a)

```
N = 10e5;  
n = 5;  
p = 0.3;  
X = 0:5;  
  
% Matriz N x 5 com 1s (defeito) e 0s (peça boa)  
amostras = rand(N, n) < p;  
defeitos_por_amostra = sum(amostras, 2);
```

```

% Função Massa de Probabilidade
Px_sim = zeros(1, length(X));
for i = 1:length(X)
    casos_favoraveis = sum(defeitos_por_amostra == X(i));
    Px_sim(i) = casos_favoraveis / N;
end

% i.
Px_sim

% ii. Gráfico da Função de Distribuição Acumulada
Fx_sim = cumsum(Px_sim);

```

```


Px_sim = 1x6
    0.1679    0.3601    0.3089    0.1322    0.0283    0.0025

```

```

figure(1);
% Usamos o "ponto fantasma" (ex: o valor 6) para a linha não morrer no 5
stairs([X 6], [Fx_sim Fx_sim(end)], 'LineWidth', 1.5);
title('a) ii. CDF Estimada por Simulação');
xlabel('Número de peças defeituosas (X)');
ylabel('Probabilidade Acumulada F_X(X)');
xticks(0:5);
ylim([0 1.1]);

```



```

% iii. Probabilidade de ter no máximo 2 peças defeituosas ( X <= 2 )
% Corresponde a X = 0, X = 1 ou X = 2 (posições 1, 2 e 3 do vetor)
prob_max_2_sim = sum(Px_sim(1:3));
fprintf('a) iii. Probabilidade simulada (<= 2 defeitos): %.4f\n', prob_max_2_sim);

```

```


a) iii. Probabilidade simulada (<= 2 defeitos): 0.8370

```

b)

```
% i. Gráfico da Função de Distribuição Acumulada Teórica
Fx_teorica = binocdf(X, n, p);

figure(2);
stairs([X 6], [Fx_teorica Fx_teorica(end)], 'r', 'LineWidth', 1.5);
title('b) i. CDF Teórica (Distribuição Binomial)');
xlabel('Número de peças defeituosas (X)');
ylabel('Probabilidade Acumulada F_X(X)');
xticks(0:5);
ylim([0 1.1]);
```



```
% ii. Probabilidade de ter no máximo 2 peças defeituosas ( X <= 2 )
% A função binocdf calcula exatamente a definição P(X <= x), logo dá a resposta
direta!
prob_max_2_teorica = binocdf(2, n, p);
fprintf('b) ii. Probabilidade teórica (<= 2 defeitos): %.4f\n', prob_max_2_teorica);
```

b) ii. Probabilidade teórica (<= 2 defeitos): 0.8369

Exercicio 5

Dado um número fixo de motores por avião (n), sabemos que cada motor pode falhar de forma completamente independente dos outros, e existe uma probabilidade p constante de um motor falhar.

Isto é a definição exata de uma variável com **Distribuição Binomial**.

O enunciado diz que o avião despenha-se se **mais de metade** ($> 50\%$) dos seus motores falharem.

O Avião de 2 motores ($n=2$):

- Mais de metade de 2 motores significa que têm de falhar rigorosamente **2 motores** para o avião cair.

- Aplicando a fórmula teórica da Binomial para calcular $P(X=2)$:

$$p_2 = p_X(2, n = 2) = \binom{2}{2} p^2 (1 - p)^{2-2} = p^2$$

O Avião de 4 motores (n=4):

- Mais de metade de 4 motores significa que o avião só cai se falharem **3 ou 4 motores**.
- Logo, a probabilidade teórica total de queda será a soma dessas duas hipóteses extremas:

$$\begin{aligned} p_4 &= p_X(3, n = 4) + p_X(4, n = 4) \\ &= \binom{4}{3} p^3 (1 - p)^{4-3} + \binom{4}{4} p^4 (1 - p)^{4-4} \\ &= 4 p^3 (1 - p) + p^4 = 4 p^3 - 3 p^4 \end{aligned}$$

Uma das sugestões no enunciado para resolver o problema é gerar um gráfico para um conjunto de valores concretos de p , permitindo ver visualmente em que situações uma linha ultrapassa a outra.

```
% 1. Criar um vetor com várias probabilidades de falha de um motor (p)
% A sugestão do guião usa logspace para gerar 100 valores desde muito pequenos
(10^-3) até 0.5
p = logspace(-3, log10(1/2), 100);
```


```
% 2. Calcular a probabilidade de queda para cada avião
P_cair2 = p.^2;

P_cair4 = 4*p.^3 - 3*p.^4;
```

```
P_cair4 = 1x100
    0.0000    0.0000    0.0000    0.0000    0.0000    0.0000    0.0000    0.0000 ...
```

```
% 3. Desenhar o gráfico comparativo
figure(3);
plot(p, P_cair2, 'b-', 'LineWidth', 1.5)
hold on;
plot(p, P_cair4, 'r--', 'LineWidth', 1.5)
hold off;

legend('2 Motores', '4 Motores', 'Location', 'best')
xlabel('Probabilidade de falha de um único motor (p)')
ylabel('Probabilidade do avião cair')
title('Segurança: Avião de 2 vs 4 Motores')
grid on;
```



Exercicio 6

1. Número fixo de bits a ser transmitidos (n).
2. Cada bit é independente dos outros.
3. Cada bit só tem dois resultados possíveis: ou chega bem ("fracasso"), ou chega com erro ("sucesso" da nossa variável).
4. A probabilidade de um bit ter erro é constante: $p = 10^{-5}$.

$$p_X(k) = \frac{\lambda^k e^{-\lambda}}{k!}$$

a) A alínea pede para calcular a probabilidade de um pacote de **100 Bytes** ser recebido **sem erros** ($X = 0$).

Como p está em bits, n também tem de estar em bits. O número de experiências será $n = 100 * 8$ (1 byte = 8 bits)

```
p = 10^-5;
n = 100 * 8;
lambda = n * p;

dist_binoA = binopdf(0,n,p)
```

```
dist_binoA =
0.9920
```

```
dist_poissonA = poisspdf(0, lambda)
```

```
dist_poissonA =
0.9920
```

b)

Agora 1000 Bytes com pelo menos 2 erros.

- Na Binomial, o pacote tem milhares de bits, logo somar as probabilidades de ter 2 erros, 3 erros, 4 erros... até ao limite máximo de bits do pacote.
- Na de Poisson, o espaço de amostragem vai até ao infinito, logo é literalmente impossível somar do 2 até ao infinito.

A melhor solução é calcular através do complemento:

```
n = 1000 * 8;  
lambda = n * p;  
  
dist_binoB = 1 - (binopdf(0,n,p) + binopdf(1,n,p))
```

```
dist_binoB =  
0.0030
```

```
dist_poissonB = 1 - (poisspdf(0, lambda) + poisspdf(1, lambda))
```

```
dist_poissonB =  
0.0030
```

Exercício 7

A distribuição de Poisson é ideal para contar eventos num **intervalo de tempo contínuo** (neste caso, chegadas de e-mails). O único parâmetro que esta distribuição tem é o lambda, que representa o número médio de ocorrências *para o intervalo de tempo*.

O lambda é elástico, ou seja, é necessário ajustar sempre o lambda para o tamanho da "janela de tempo" que a pergunta pede.

a)

```
lambda = 5*2;  
poisson_teoricoA = sum(poisspdf(0:9, lambda))
```

```
poisson_teoricoA =  
0.4579
```

```
% ou poisscdf(9, lambda)
```

```
N = 10e5;  
sim = poissrnd(lambda,1, N) < 10;  
casos_fav = sum(sim);  
poisson_simA = casos_fav / N
```

```
poisson_simA =  
0.4584
```

b)

```
lambda = 5*5;  
poisson_teoricoB = 1 - sum(poisspdf(0:30, lambda))
```

```
poisson_teoricoB =  
0.1367
```

```
% ou 1 - poisscdf(30, lambda)
```


```
N = 10e5;  
sim = poissrnd(lambda,1, N) > 30;  
casos_fav = sum(sim);  
poisson_simB = casos_fav / N
```

```
poisson_simB =  
0.1362
```

Exercício 8

a)

```
lambda = 1;  
mu = 1 / lambda;  
  
x = 0:0.1:10;  
f = exppdf(x,mu);  
figure(1);  
  
plot(x, f, 'r', 'LineWidth', 2);  
title('a) PDF da Distribuição Exponencial (\lambda = 1)');  
xlabel('Valores de X');  
ylabel('Densidade de Probabilidade f_X(x)');  
grid on;
```




b)

```
N = 1e5;
sim = exprnd(mu,1,N);

histogram(sim, 100, 'Normalization', 'pdf', 'EdgeColor', 'none');
hold on;

plot(x, f, 'r', 'LineWidth', 2);
hold off;

title('b) Simulação vs Teoria (Distribuição Exponencial)');
xlabel('Valores de X');
ylabel('Densidade de Probabilidade (PDF)');
legend('Histograma (Simulação)', 'Linha Teórica (exppdf)');
grid on;
```



Exercício 9

a)

```
lambda = 0.2;  
mu = 1 / lambda % média teórica
```

```
mu =  
5
```

```
N = 1e5;
```

```
gen = exprnd(mu, 1, N);  
mu_sim = mean(gen) % média simulada
```

```
mu_sim =  
5.0175
```

b)

```
% Provar:  $P(X > 5 \mid X > 3) = P(X > 2)$ .
```

```
s = 2;
```

```
t = 3;
```

```
% 1. Calcular  $P(X > s)$  de forma direta
```

```
% (Quantos casos são > 2, a dividir pelo total de experiências)
```

```
prob_s = sum(gen > s) / N;
```

```
% 2. Calcular  $P(X > s+t \mid X > t)$  (Probabilidade Condicionada)
```

```
% A melhor prática para calcular isto em Matlab:
```

```
casos_condicao = sum(gen > t); % Quantas simulações duraram mais de 3?
```

```
casos_favoraveis = sum(gen > (s + t)); % Dentre essas, quantas passaram dos 5?
```

```
prob_condicionada = casos_favoraveis / casos_condicao;
```

```
fprintf('P(X > %d) = %.4f\n', s, prob_s);
```

```
P(X > 2) = 0.6724
```

```
fprintf('P(X > %d | X > %d) = %.4f\n', s+t, t, prob_condicionada);
```

```
P(X > 5 | X > 3) = 0.6714
```

Exercício 10

```
lambdaX = 0.4;
```

```

lambdaY = 0.1;
muX = 1 / lambdaX;
muY = 1 / lambdaY;
N = 1e5;

X = exprnd(muX, 1, N);
Y = exprnd(muY, 1, N);

casos_fav = sum(X < Y);
sim = casos_fav / N;

teorica = lambdaX / (lambdaX + lambdaY);

fprintf('Probabilidade Teórica: %.4f\n', teorica);

```

```

Probabilidade Teórica: 0.8000

```

```

fprintf('Probabilidade Simulada: %.4f\n', sim);

```

```

Probabilidade Simulada: 0.7990

```

Exercicio 11

O enunciado diz explicitamente que a taxa $\lambda = 0.02$ representa erros **por página**. No entanto, a pergunta quer saber a probabilidade para um livro inteiro de **100 páginas**.

```

lambda = 0.02 * 100;

probEx11 = sum(poisspdf(0:1, lambda))

```

```

probEx11 =
0.4060

```

```

% ou poisscdf(1, lambda)

```

Exercicio 12

"Qual é a probabilidade do número aleatório de alunos (X) ser menor ou igual à capacidade total das turmas?"

A capacidade total para n turmas é simplesmente $C = n * 20$. Logo, queremos calcular $P(X \leq C)$.

```

N = 1e5;

```

```

media = 100;
desvio = 10;

% Gerar os valores usando o randn (ajustado à média e desvio pretendido)
X = media + desvio * randn(1, N);

turmas = [5, 6, 7];

for n = turmas
    capacidade = n * 20;

    % a) Probabilidade Simulada: Fração de vezes que X <= capacidade
    casos_fav = sum(X <= capacidade);
    prob_simulada = casos_fav / N;

    % b) Probabilidade Teórica: Usando a CDF da Normal
    prob_teorica = normcdf(capacidade, media, desvio);

    % Imprimir a comparação
    fprintf('Turmas: %d (Capacidade: %d alunos)\n', n, capacidade);
    fprintf('  Simulada: %.4f\n', prob_simulada);
    fprintf('  Teórica:   %.4f\n\n', prob_teorica);
end

```

```

Turmas: 5 (Capacidade: 100 alunos)
  Simulada: 0.4998
  Teórica:   0.5000
Turmas: 6 (Capacidade: 120 alunos)
  Simulada: 0.9768
  Teórica:   0.9772
Turmas: 7 (Capacidade: 140 alunos)
  Simulada: 1.0000
  Teórica:   1.0000

```

- Para **n = 5** (capacidade 100): Como a capacidade é exatamente igual à média (100), a probabilidade de haver 100 alunos ou menos será exatamente metade da curva, ou seja, **50% (0.5000)**.
- Para **n = 6** (capacidade 120): Estás a abranger quase a curva toda (2 desvios padrão acima da média), pelo que a probabilidade salta para perto de **97.7%**.
- Para **n = 7** (capacidade 140): Já estás 4 desvios padrão acima da média. A probabilidade de o número de alunos ficar abaixo de 140 é **100% (1.0000)**.

Exercício 13

Média de uma bolacha: $\mu = 20$ g

Variância de uma bolacha: $\sigma^2 = 9$ g²

O peso de um pacote inteiro com n bolachas é a soma de todas elas.

```
mu = 20;
```

```
sigma = 9;  
  
n = randi(100,1);
```

a)

- O Valor Esperado de uma soma é sempre a soma dos Valores Esperados.
- A Variância de uma soma só é igual à soma das Variâncias se as variáveis forem independentes (o enunciado diz que são "i.i.d.")

```
ESn = n*20;  
var = n*9;
```

b)

A alínea pede para descobrir um limite superior para a probabilidade de uma única bolacha pesar 30 gramas ou mais ($P(X \geq 30)$), **usando apenas a média** (ignorando a variância).

Sempre que pedem um "majorante" ou "upper bound" usando *apenas* médias, a ferramenta universal é a **Desigualdade de Markov**.

A fórmula teórica:

$$P(X \geq a) \leq \frac{E[X]}{a}$$

(Desde que a variável só assuma valores positivos, o que é o caso do peso de uma bolacha)

```
probB = 20 / 30
```

```
probB =  
0.6667
```

c)

A alínea pede para limitar a probabilidade de uma única bolacha desviar-se da sua média em mais de 10 gramas, **usando a média e a variância**.

Sempre que o enunciado dá a variância (σ^2) e pede para limitar a probabilidade de um valor se desviar, a ferramenta matemática universal é a **Desigualdade de Chebyshev**.

A fórmula teórica:

$$P(|X - \mu| \geq a) \leq \frac{\sigma^2}{a^2}$$

(A probabilidade de a distância entre o valor e a média ser maior ou igual a a, é menor ou igual à variância a dividir por a^2)

```
a = 10;
probC = 9/10^2
```

```
probC =
0.0900
```

d)

O TLC (Teorema do Limite Central) diz que, independentemente da forma que a distribuição original tenha (neste caso, o peso de uma bolacha individual), se **somar-mos muitas variáveis independentes** (n grande, geralmente > 30), essa **soma vai ter sempre uma Distribuição Normal (Gaussiana)**.

Como n = 100 bolachas, o peso total S_{100} segue uma distribuição Normal. E para usar o normcdf do Matlab, só é necessário de duas informações:

1. A Média
2. O Desvio Padrão (raiz quadrada da Variância)

```
n = 100;

% pacote inteiro (S_100)
mu_pacote = n * 20;
var_pacote = n * 9;
desvio_pacote = sqrt(var_pacote);

% Calcular a probabilidade do intervalo [1970, 2030]
% P(1970 <= S100 <= 2030) = CDF(2030) - CDF(1970)
prob_max = normcdf(2030, mu_pacote, desvio_pacote);
prob_min = normcdf(1970, mu_pacote, desvio_pacote);

probD = prob_max - prob_min;

fprintf('d) Probabilidade do pacote pesar entre 1970g e 2030g (TLC): %.4f\n',
probD);
```

d) Probabilidade do pacote pesar entre 1970g e 2030g (TLC): 0.6827