# Cadeias de Markov

# ?!

- O que esteve na origem do grande sucesso inicial da Google ?
- O que tem em comum esse sucesso com a capacidade de interagir por voz com computadores, robôs e smartphones ?
  - No reconhecimento de fala ?
  - Na síntese de fala ?
- E com a modelação do comportamento de uma ligação de rede sujeita a falhas?

# Exemplo 1

- Suponhamos que em cada dia que têm aulas TP de MPECI acordam e decidem se vêm ou não à aula.
- Se vieram à aula anterior, a probabilidade de virem é 70%;
- se faltaram à anterior, essa probabilidade é 80%

- Algumas questões:
  - Se vieram à aula esta segunda, qual a probabilidade de virem na aula de SEGUNDA da próxima semana ?
  - Assumindo que o semestre tem duração infinita, qual a percentagem aproximada de aulas a que estariam presentes ?

# Exemplo 2

- Imagine uma ligação entre dois computadores (A → B) que, a cada **intervalo de tempo discreto** (slot), pode estar em um de **dois estados**:
- **Bom (B):** a transmissão é bem-sucedida.
- **Mau (M):** a ligação está degradada (pacote perdido).
- O estado no instante seguinte **depende apenas do estado atual**; se a ligação está no estado **B** tem probabilidade 90% de se manter nesse estado, se está no estado **M** tem probabilidade de 50% de se manter no mesmo estado.
- Em média quanto tempo estará a ligação em cada um dos estados?

# Outro exemplo

- Passeio aleatório (random walk)

Lançar moeda

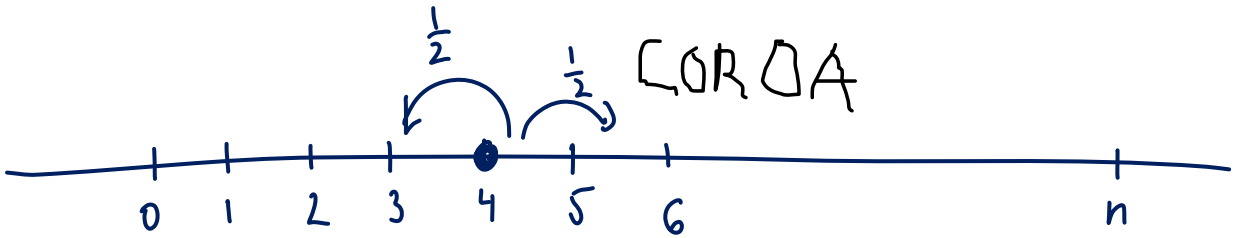


Cara Coroa Coroa … Cara …

# Muitas áreas de aplicação

- Muitas vezes estamos interessados na transição de algo entre certos estados.
- Exemplos:
  - Movimento de pessoas entre regiões
  - Estado do tempo
  - Movimento entre as posições num jogo de Monopólio
  - Pontuação ao longo de um jogo
  - Estado de Filas de atendimento

# Princípios básicos

# Processos estocásticos

- Estendem o conceito de variável aleatória
- Lidam com a dinâmica da teoria de probabilidades

- Uma v.a. $X$ mapeia um acontecimento $s \in \Omega$ num número $X(s)$
- O processo mapeia o acontecimento para números diferentes em tempos diferentes
  - O que implica que em lugar de termos um número $X(s)$ temos $X(t, s)$
    - Sendo t$\in T$ geralmente um conjunto de tempos

# Processos estocásticos

- 3 realizações de um processo estocástico

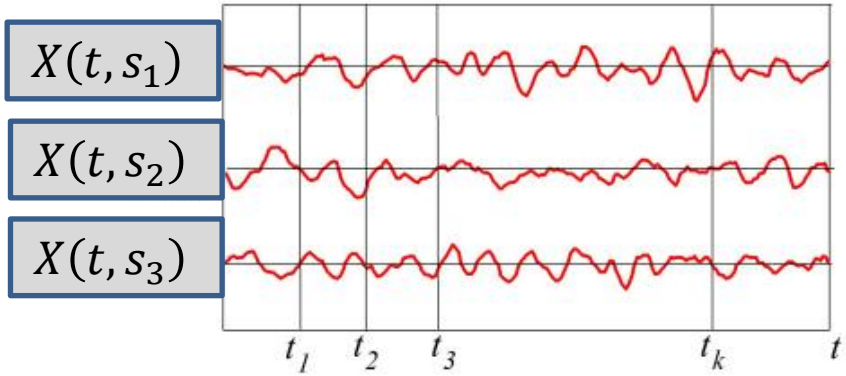


- Se fixarmos $s$, $X(t)$ é uma função real do tempo
- $X(t, s)$ pode então ser vista como uma coleção de funções no tempo
- Se fixarmos $t$ temos uma função $X(s)$ que depende apenas de $s$, ou seja é uma variável aleatória
- Um nome alternativo é processos aleatórios

# Classificação de processos estocásticos

- Podem ser classificados segundo $t$ e os valores que pode assumir (estados do processo)

- Quanto ao tempo :
  - Tempo contínuo: Se tempo é um intervalo contínuo
  - Tempo discreto: Se o tempo é um conjunto contável
    - Também chamada sequência aleatória e representada por $X[n]$
- Quanto ao conjunto de estados (E):
  - Contínuo
  - Discreto

# Estados

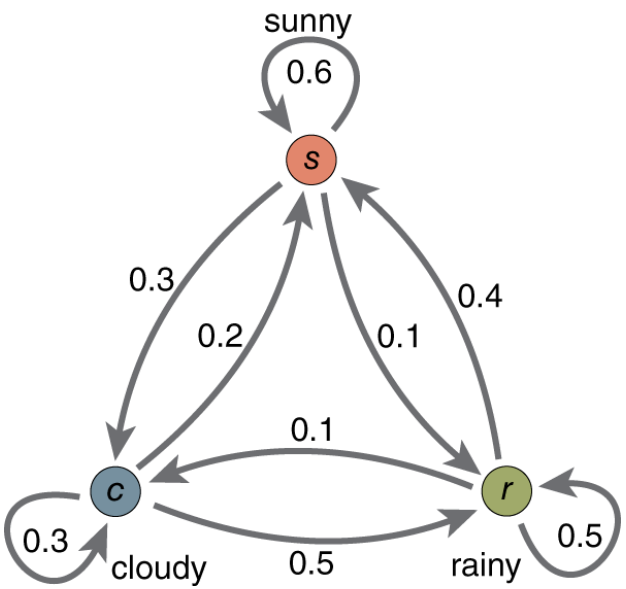
sunny
0.6
s
0.3
0.2
0.1
0.4
0.1
c
r
0.3
cloudy
0.5
rainy
0.5

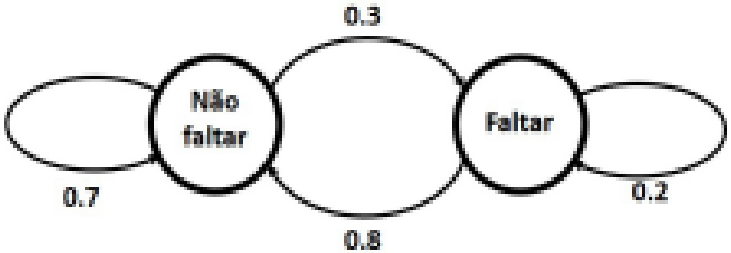
0.3
Não faltar
Faltar
0.7
0.2
0.8

# Definição

- Um processo de Markov é um processo estocástico em que a probabilidade de o sistema estar num estado específico num determinado período de observação depende apenas do seu estado no período de observação imediatamente precedente
  - O futuro apenas depende do presente e não do passado

# Tipos de processos de Markov

| | | Espaço de estados | |
|---|---|---|---|
| | | Discreto | Contínuo |
| Tempo | Discreto | **Cadeia de Markov de tempo discreto** | Processo de Markov em tempo discreto |
| | Contínuo | **Cadeia de Markov de tempo contínuo** | Processo de Markov em tempo contínuo |

- Focaremos a nossa atenção em cadeias de Markov de tempo discreto e de tempo contínuo com espaço de estados discreto (isto é, com um número de estados finito ou infinito, mas contável).

# Cadeias de Markov de tempo e estados discretos

- $X_n$: estado após *n* transições
  - Pertence a um conjunto finito (em alguns casos pode ser um conjunto infinito mas contável),
    - Em geral $\{1, 2, \dots, m\}$
  - $X_0$ é dado ou aleatório (estado inicial)

# Questões comuns relativas a cadeias de Markov

- Qual é a probabilidade de transitar do estado $i$ para o estado $j$ em $n$ passos?
- Existe uma distribuição estacionária (ou estado de equilíbrio)?
- A cadeia converge para essa distribuição a longo prazo (independentemente do estado inicial)?

# Propriedade de Markov

- Probabilidade de transição do estado $i$ para o estado $j$:

- $\boldsymbol{p_{ji}} = P(X_{n+1} = j | X_n = i, X_{n-1} = x_{n-1}, \dots, X_0 = x_0)$

  $= \boldsymbol{P(X_{n+1} = j | X_n = i)}$

- Quando estas probabilidades $\boldsymbol{p_{ji}}$ não dependem de *n* a cadeia diz-se **homogénea**
  - Focaremos a nossa atenção neste tipo de cadeias de Markov

# Propriedade de Markov

- $P(X_0 = x_0, X_1 = x_1, X_2 = x_2 \dots) = ?$

$$= P(X_0 = x_0)\, P(X_1 = x_1 | X_0 = x_0)\, P(X_2 = x_2 | X_0 = x_0, X_1 = x_1) \dots$$

$$= P(X_0 = x_0)\, P(X_1 = x_1 | X_0 = x_0)\, P(\boldsymbol{X_2 = x_2 | X_1 = x_1}) \dots$$

- O processo "não tem memória"

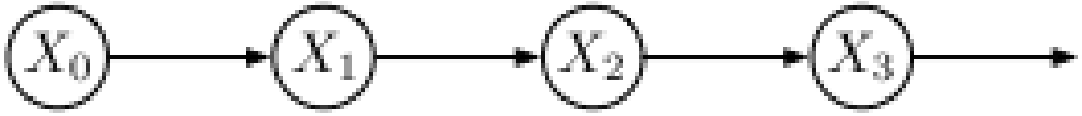

# Especificação de uma cadeia

- Identificar os estados possíveis
- Identificar as transições possíveis
- Identificar as probabilidades de transição

# Aplicando ao exemplo 1 – faltar ou não faltar à aula

- Estados ?
- Transições ?
- Probabilidades de transição ?

# Aplicando ao exemplo 1 – faltar ou não faltar à aula

- Estados ?
  - 2: {faltar, não faltar}
- Transições ?
  - Não faltar -> não faltar
  - Faltar -> não faltar
  - Não faltar -> faltar
  - Faltar -> faltar
- Probabilidades de transição ?
  - Não faltar -> não faltar: 0,7
  - Faltar -> não faltar : 0,8
  - Não faltar -> faltar : 0,3
  - Faltar -> faltar : 0,2

# Matriz de transição

- É usual representar as probabilidades de transição através de uma matriz, **chamada de matriz de transição**
- Tendo o sistema $n$ estados possíveis, para cada par $i, j$ fazemos $t_{ji}$ igual à probabilidade de mudar **do estado $i$ para o estado $j$**.
- A matriz $T$ cujo valor na posição $\text{linha} = j, coluna = i$ é $t_{ji}$ é a matriz de transição

$X_n$

$X_{n+1}$

$$T = \begin{pmatrix} t_{11} & \cdots & t_{1n} \\ \vdots & \ddots & \vdots \\ t_{n1} & \cdots & t_{nn} \end{pmatrix}$$

  - Nota: Alguns autores adoptam $t_{ij}$ como a probabilidade de mudar do estado $i$ para o estado $j$

# Matriz T do Exemplo 1

- $T = \begin{pmatrix} ? & ? \\ ? & ? \end{pmatrix}$

- Considerando estado 1 “não faltar”, temos

- $T = \begin{array}{ll} não\ faltar & \rightarrow \\ faltar & \rightarrow \end{array} \begin{pmatrix} 0{,}7 & 0{,}8 \\ 0{,}3 & 0{,}2 \end{pmatrix}$

# Matriz T do Exemplo 2

$$T = \begin{array}{c} \\ B \\ M \end{array} \begin{array}{c} \begin{array}{cc} B & M \end{array} \\ \begin{bmatrix} 0{,}9 & 0{,}5 \\ 0{,}1 & 0{,}5 \end{bmatrix} \end{array}$$

# Matriz T é estocástica

- A matriz de transição reflecte propriedades importantes  das probabilidades:
  - Todas as entradas são não-negativas
  - Os valores em cada COLUNA somados dão sempre resultado 1
- Devido a estas propriedades a matriz é denominada de **matriz estocástica**

# Representação gráfica da cadeia

- Apropriada e possível para número de estados pequeno

- Nós: representam todos os estados
- Setas: para todas as transições permitidas (one-step)
  - Ou seja, seta entre *i* e *j* apenas de $p_{ji} > 0$

# Representação gráfica da cadeia

- Exemplo:

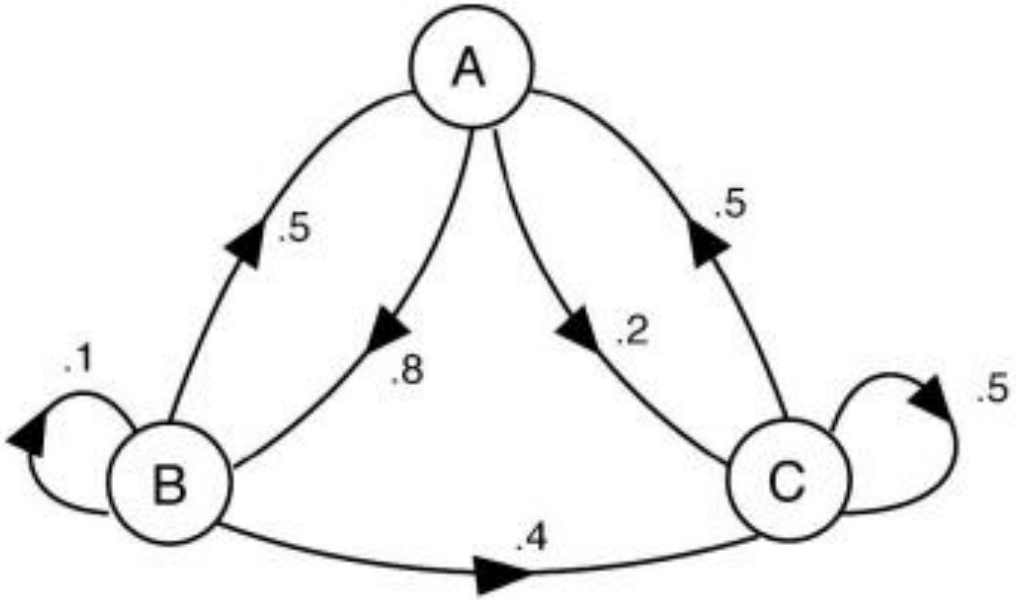

# Simulação / Visualização dinâmica

- Estão disponíveis online formas de visualizar as transições entre estados ao longo do tempo …
- Um desses exemplos é **Markov Chains - A visual explanation by Victor Powell**
  - http://setosa.io/blog/2014/07/26/markov-chains/index.html

  Que inclui:
  - http://setosa.io/markov/index.html#%7B%22tm%22%3A%5B%5B0.5%2C0.5%5D%2C%5B0.5%2C0.5%5D%5D%7D

- Para usar precisamos apenas de introduzir a matriz T
  - Que define o número de estados, quais as transições possíveis e as probabilidades associadas a essas transições (Nota: a notação é diferente da usada em MPECI)

# Simulando os nossos exemplos

- Exemplo 1:
  - Matriz:
    [ [ 0.7, 0.3],
    [ 0.8, 0.2] ]
  - http://setosa.io/markov/index.html#%7B%22tm%22%3A%5B%5B0.7%2C0.3%5D%2C%5B0.8%2C0.2%5D%5D%7D

- Outro exemplo
  [ [0,1,0,0],
  [0,0,1,0],
  [0,0,0,1],
  [0.2,0.3,0.3,0.2]]

  - O que vamos ver ?

  - Acesso directo:
  http://setosa.io/markov/index.html#%7B%22tm%22%3A%5B%5B0%2C1%2C0%2C0%5D%2C%5B0%2C0%2C1%2C0%5D%2C%5B0%2C0%2C0%2C1%5D%2C%5B0.2%2C0.3%2C0.3%2C0.2%5D%5D%7D

# Estado da cadeia num determinado instante

- O **estado** de uma cadeia de Markov com *n* estados no tempo (time step) $k$ é dado pelo vector estado

$$\mathbf{x}^{(k)} = \begin{pmatrix} \boldsymbol{p_1}^{(k)} \\ \boldsymbol{p_2}^{(k)} \\ \\ \boldsymbol{p_n}^{(k)} \end{pmatrix}$$

- Onde ${p_j}^{(k)}$ é a probabilidade de o sistema estar no estado $j$ no instante de tempo $k$

# Vector estado/probabilidade

- Considerando o exemplo 1:
- Suponhamos que após 10 aulas a probabilidade de faltar e não faltar são iguais
- Então o vector representativo do estado (state vector) seria:

$$\mathbf{x}^{(10)} = \begin{pmatrix} 0{,}5 \\ 0{,}5 \end{pmatrix}$$

- Este vector também se designa por **vector de probabilidade**
  - Todos os elementos não-negativos
  - Soma dos elementos igual a um

# Exemplo 2

- Supondo que no instante 0 a ligação tem o triplo da probabilidade de estar no estado Bom do que no estado Mau o vetor de probabilidade é:

$$\mathbf{x}^{(0)} = \begin{pmatrix} 0{,}75 \\ 0{,}25 \end{pmatrix}$$

# Vector estado após uma transição

- Como obter $\mathbf{x}^{(k+1)}$ ?

- O vector de estado $\mathbf{x}^{(k+1)}$ no período de observação $k+1$ pode ser determinado a partir do vector $\mathbf{x}^{(k)}$ através de:

$$\mathbf{x}^{(k+1)} = T\mathbf{x}^{(k)}$$

- Que resulta da probabilidade condicional:
- $P(\ estado\ j\ em\ t = k+1)$

$$= \sum_{\mathrm{i}=1}^{n} P(transição\ do\ estado\ i\ para\ o\ j) P(estado\ \mathrm{i}\ em\ t = k)$$

# Exemplo de aplicação – Exemplo 1

- De que forma depende a probabilidade de ir à aula seguinte da probabilidade de estar na aula actual ?

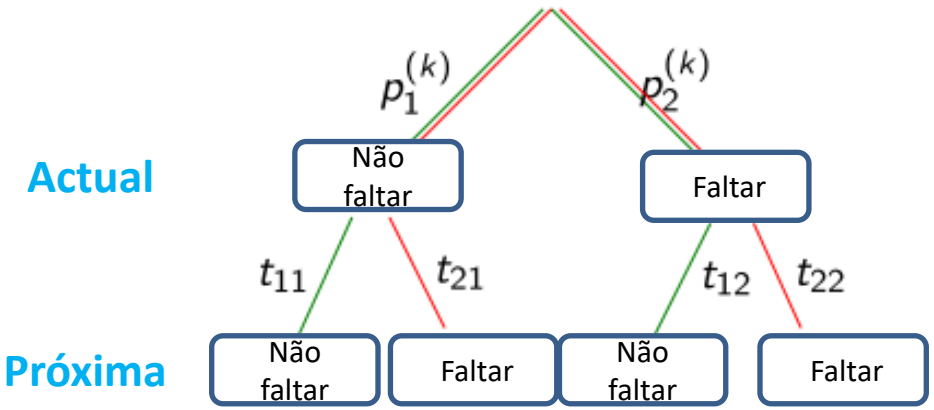


$$p_1^{(k+1)} = t_{11}p_1^{(k)} + t_{12}p_2^{(k)}$$

$$p_2^{(k+1)} = t_{21}p_1^{(k)} + t_{22}p_2^{(k)}$$

# Estado após múltiplas transições

- Ataquemos agora problemas do “tipo”:
  - Qual é a probabilidade de transitar do estado $i$ para o estado $j$ em $n$ passos?
- Exemplo 1:
  - Qual a probabilidade de um aluno que veio à aula de uma segunda vir também à aula na segunda seguinte?
    - Assumindo as probabilidades do nosso exemplo !
    - Tendo em conta que temos aulas segunda e quarta (TP1).

# Equações de Chapman-Kolmogorov

- Definindo a transição em $n$ passos ${p_{ji}}^{(n)}$ como a probabilidade de **um processo no estado *i* se encontrar no estado *j* após *n* transições** adicionais. Ou seja:
- ${p_{ji}}^{(n)} = P(X_{n+k} = \boldsymbol{j} | X_k = \boldsymbol{i}),\ n \geq 0, i, j \geq 0$

- Obviamente ${p_{ji}}^{(1)} = p_{ji}$
- As **equações de Chapman-Kolmogorov** permitem calcular estas probabilidades

$$ {p_{ji}}^{(n+m)} = \sum_k {p_{ki}}^{(n)}\ {p_{jk}}^{(m)} \quad \forall n, m \geq 0, \forall i, j $$

# Interpretação

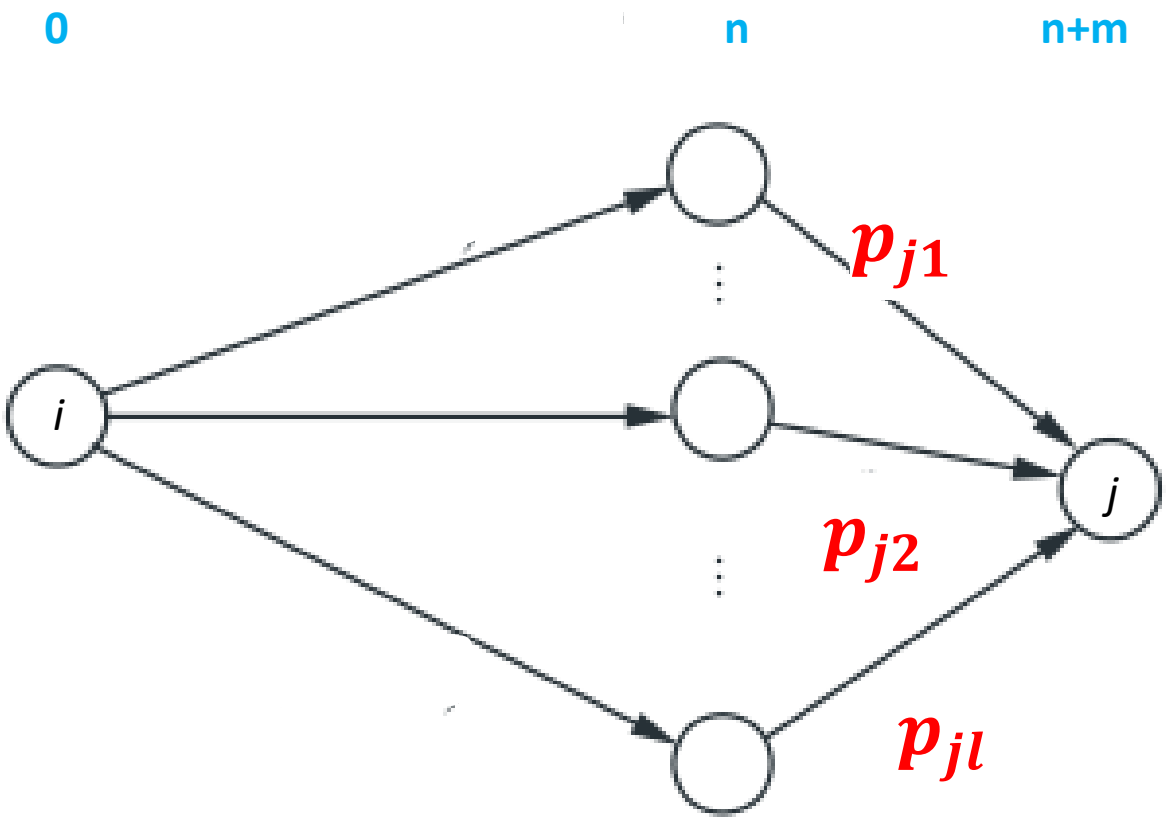

# Interpretação

- É fácil de compreender se tivermos em conta que ${p_{ki}}^{(n)}{p_{jk}}^{(m)}$ representa a probabilidade de:
  - Começando em $i$ o processo ir para o estado $j$ em $n + m$ transições..
  - Através de um caminho que o leva ao estado $k$ na transição $n$

- Logo, somando para todos os estados intermédios $k$ obtém-se a probabilidade de estar no estado $j$ ao fim de $n + m$ transições

# Em termos de matrizes

- Se usarmos $\mathbf{T}^{(\mathbf{n})}$ para representar a matriz com as probabilidades de *n* transições, a equação anterior transforma-se em:

$$\mathbf{T}^{(n+m)} = \mathbf{T}^{(n)} * \mathbf{T}^{(m)}$$

Em que o "*" significa multiplicação de matrizes

- Desta equação obtém-se facilmente:

$$\mathbf{T}^{(2)} = \mathbf{T}^{(1+1)} = \mathbf{T} * \mathbf{T} = \mathbf{T}^{2}$$

- E por indução $\mathbf{T}^{(n)} = \mathbf{T}^{(n-1+1)} = \mathbf{T}^{n-1} * \mathbf{T} = \mathbf{T}^{n}$
  - Ou seja, a matriz de transição relativa a *n* transições pode ser obtida multiplicando $\mathbf{T}$ por si própria *n* vezes

# Aplicação ao Exemplo 1

- Voltando a uma questão colocada no início da aula …

- *Se vieram à aula esta segunda, qual a probabilidade de virem na aula de SEGUNDA da próxima semana ?*

- Solução:
- Temos $\mathbf{x}^{(0)} = \begin{pmatrix} 1 \\ 0 \end{pmatrix}$ , significando "não faltar"
- Pretendemos $\mathbf{x}^{(2)}$ , instante 0 = hoje, 2 aulas por semana

…

- $\mathbf{x}^{(2)} = \mathrm{T}\mathbf{x}^{(1)} = T\left(T\mathbf{x}^{(0)}\right) = T^2\mathbf{x}^{(0)}$

$$= \begin{pmatrix} 0{,}7 & 0{,}8 \\ 0{,}3 & 0{,}2 \end{pmatrix}^2 \begin{pmatrix} 1 \\ 0 \end{pmatrix} = \begin{pmatrix} 0{,}7 & 0{,}8 \\ 0{,}3 & 0{,}2 \end{pmatrix} \begin{pmatrix} 0{,}7 \\ 0{,}3 \end{pmatrix}$$
$$= \begin{pmatrix} 0{,}73 \\ 0{,}27 \end{pmatrix}$$

- Ou seja  probabilidade de 0,73 de virem na próxima segunda

# Terminologia

Tipos de estados

Tipos de matrizes de transição

...

# Acessibilidade de um estado

- Possibilidade de ir do estado *i* para o estado *j* (existe caminho na cadeia de *i* para *j*).

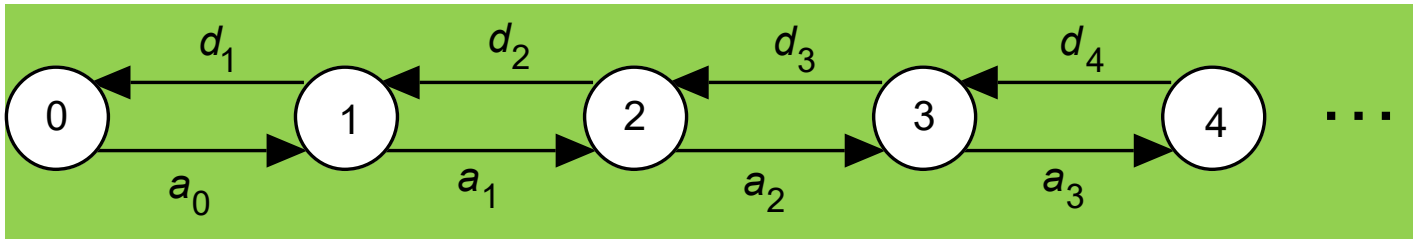


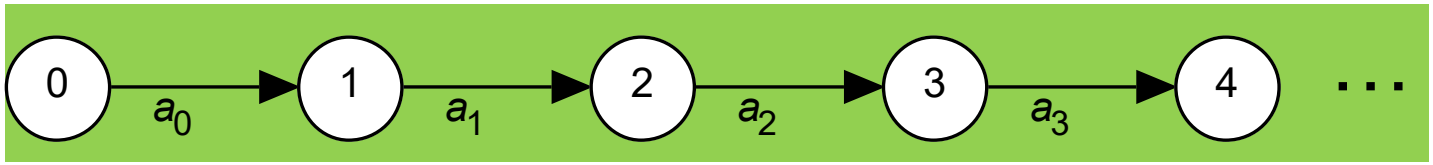

# Estados comunicantes

- Dois estados comunicam se ambos são acessíveis a partir do  outro.

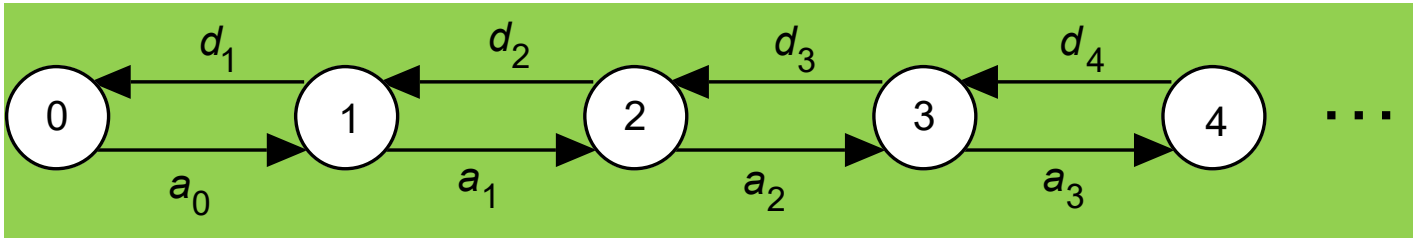


- Um sistema  é não redutível (irreducible)  se todos os estados comunicam

- **Classe**:  conjunto de estados que comunicam entre si

# Estado recorrente

- Um estado $s_i$ é um **estado recorrente** se o sistema puder sempre voltar a ele (depois de sair dele).

- De uma forma mais formal: $s_i$ é um **estado recorrente** se, para todos os estados $s_j$, a existência de um inteiro $r_j$ tal que ${p_{ji}}^{(r_j)} > 0$ implica que existe um inteiro $r_i$ tal que ${p_{ij}}^{(r_i)} > 0$

- Um estado não recorrente é transiente

# Estados recorrentes ?

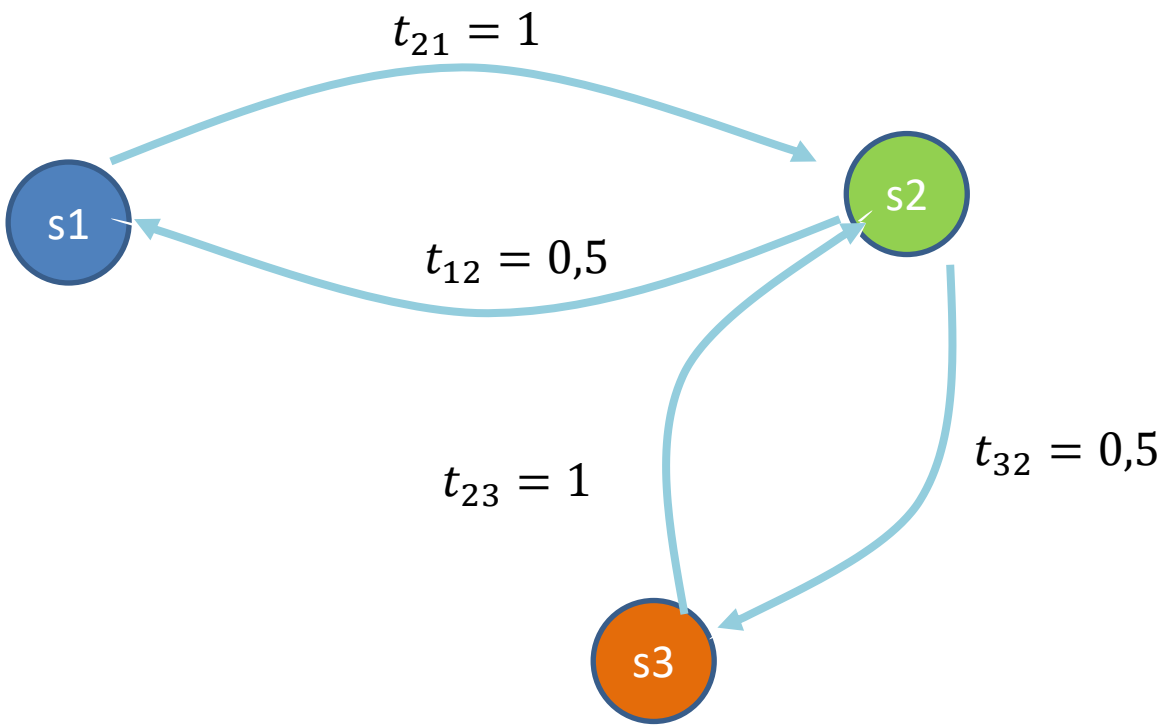


- Os 3 estados são recorrentes

# Estado transiente

- Um estado é transiente se existe um outro estado qualquer para o qual o processo de Markov pode transitar, mas do qual o processo não pode retornar

- Ou seja, se existe um estado $s_j$ e um inteiro $l$ tal que ${p_{ji}}^{(l)} \neq 0$ e ${p_{ij}}^{(r)} = 0$ para $r = 0,1,2, \ldots$

- A probabilidade destes estados tende para zero quando *n* tende para infinito
  - Pois apenas são visitados um número finito de vezes

# Estado periódico

- Um estado é **periódico** se apenas se pode regressar a ele após um número fixo de transições superior a 1 (ou múltiplos desse número).

- Formalizando:
  - Um estado recorrente $s_i$ diz-se **periódico** se existe um inteiro $c > 1$ tal que ${p_{ii}}^{(r)}$ é igual a zero para todos os valores de $r$ excepto $r = c, 2c, 3c, \ldots$

# Estado periódico

.

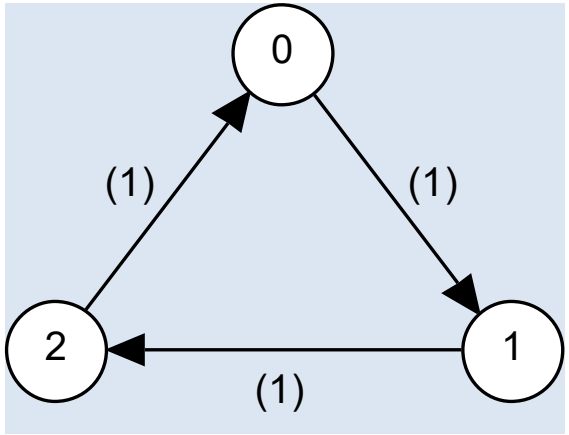


Todos estados visitados em múltiplos de 3 iterações

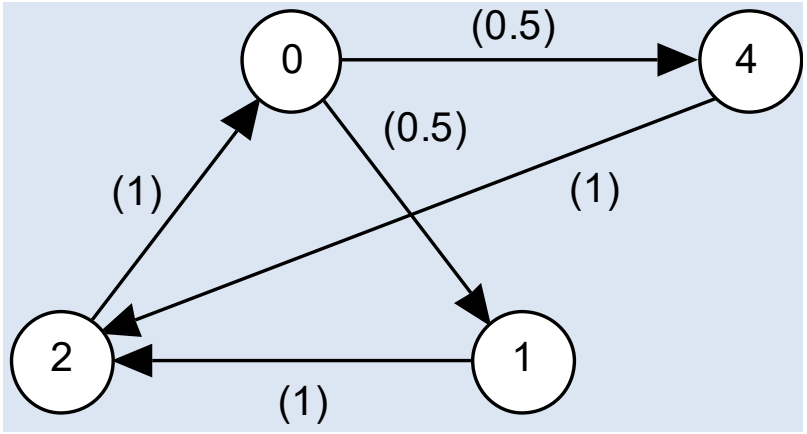


Todos estados visitados em múltiplos de 3 iterações

- Um estado não periódico é **aperiódico**
  - Como era de esperar!

# Estado absorvente

- Um estado **absorvente** é um estado do qual não é possível sair (ou seja transitar para outro estado)
- Uma cadeia é absorvente se tiver pelo menos um estado absorvente

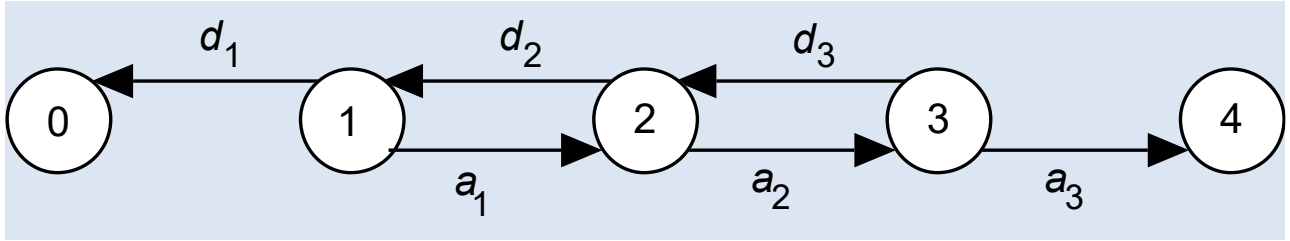


- Os estados 0 e 4 são absorventes

# Aplicação dos conceitos

- Exemplo:

$$
\begin{array}{c|cccc}
\text{State} & 0 & 1 & 2 & 3 \\
\hline
0 & 0 & X & X & 0 \\
1 & X & 0 & 0 & 0 \\
2 & 0 & 0 & 0 & X \\
3 & X & 0 & 0 & X
\end{array}
$$

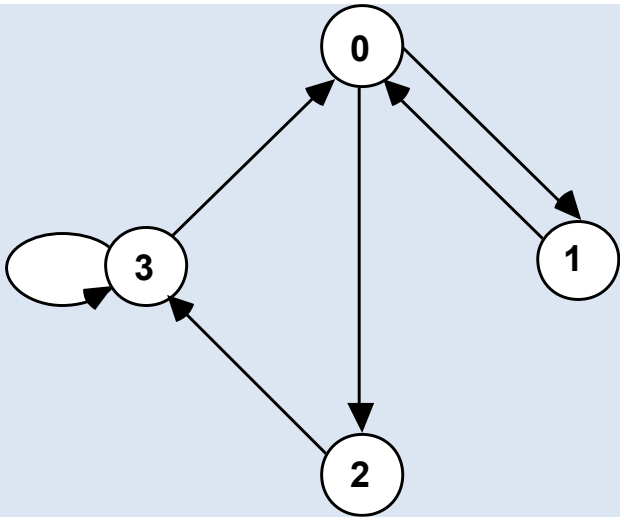


- Todos os pares de estados comunicam, formando um única classe recorrente
  - Os estados são aperiódicos
- Em consequência o processo é aperiódico e irredutível

# Assuntos principais dados anteriormente

- Noção de processo estocástico
- Cadeias de Markov
- Propriedade de Markov
- Matriz de transição $T$
- Representação gráfica
- $\mathbf{T}^{(n)}$

# Demos

- **Wolfram:**
  - **Finite-State, Discrete-Time Markov Chains**
    - **http://demonstrations.wolfram.com/ATwoStateDiscreteTimeMarkovChain/**
    - **http://demonstrations.wolfram.com/FiniteStateDiscreteTimeMarkovChains/**

# O que acontece ao fim de muitas transições ?

# Potências de $T$ quando $n \to \infty$

- Exemplo 2 (3 grupos de alunos):
- Vejamos o comportamento de $T^n$ ao aumentar $n$…

$$T = \begin{pmatrix} 0.333333 & 0.25 & 0. \\ 0.333333 & 0.5 & 0.5 \\ 0.333333 & 0.25 & 0.5 \end{pmatrix}$$

$$T^2 = \begin{pmatrix} 0.194444 & 0.208333 & 0.125 \\ 0.444444 & 0.458333 & 0.5 \\ 0.361111 & 0.333333 & 0.375 \end{pmatrix}$$

$$T^3 = \begin{pmatrix} 0.175926 & 0.184028 & 0.166667 \\ 0.467593 & 0.465278 & 0.479167 \\ 0.356481 & 0.350694 & 0.354167 \end{pmatrix}$$

$$T^4 = \begin{pmatrix} 0.17554 & 0.177662 & 0.175347 \\ 0.470679 & 0.469329 & 0.472222 \\ 0.353781 & 0.353009 & 0.352431 \end{pmatrix}$$

$$T^5 = \begin{pmatrix} 0.176183 & 0.176553 & 0.176505 \\ 0.470743 & 0.47039 & 0.470775 \\ 0.353074 & 0.353057 & 0.35272 \end{pmatrix}$$

$$T^6 = \begin{pmatrix} 0.176414 & 0.176448 & 0.176529 \\ 0.470636 & 0.470575 & 0.470583 \\ 0.35295 & 0.352977 & 0.352889 \end{pmatrix}$$

# Continuando… (em Matlab)

% n =10

Tn =

| | | |
|---|---|---|
| 0.1765 | 0.1765 | 0.1765 |
| 0.4706 | 0.4706 | 0.4706 |
| 0.3529 | 0.3529 | 0.3529 |

% n=100

Tn =

| | | |
|---|---|---|
| 0.1765 | 0.1765 | 0.1765 |
| 0.4706 | 0.4706 | 0.4706 |
| 0.3529 | 0.3529 | 0.3529 |

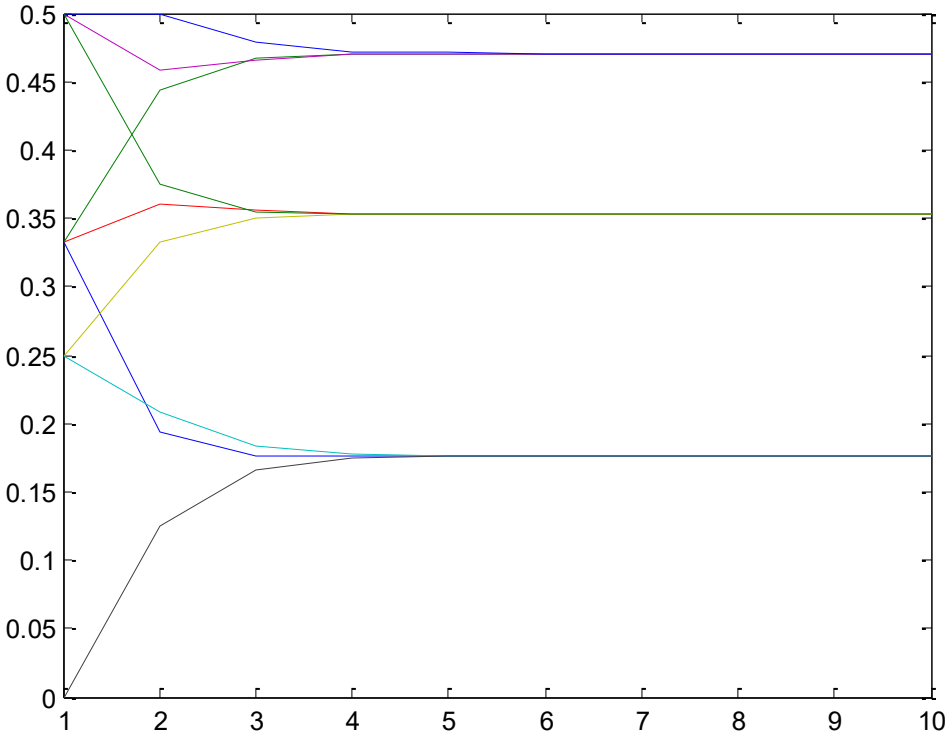

# Exemplo 1 (faltar/não faltar)

```
T=[0.7 0.8
    0.3 0.2]
Tn= T;
pij= Tn(:);
for n=2:10
   Tn= T*Tn;
   pij=[ pij  Tn(:)];
   plot(pij')
   drawnow
end
Tn
```

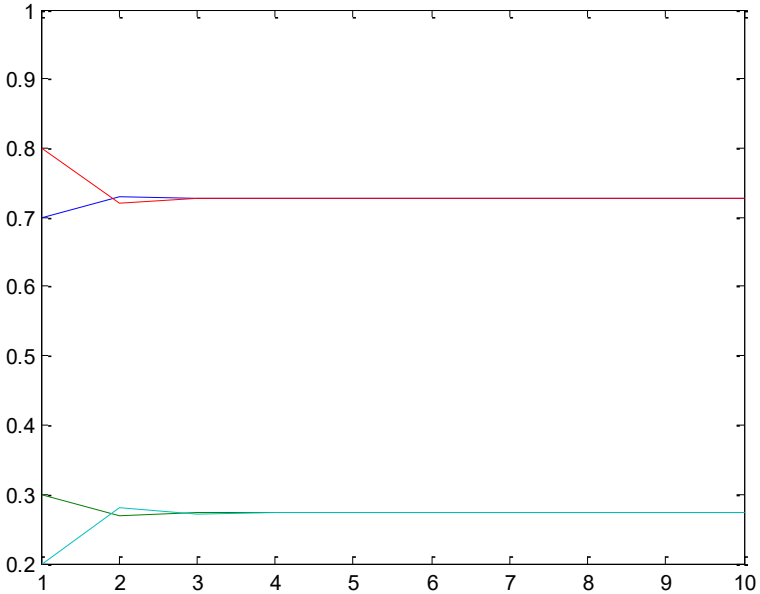


```
Tn =

   0.7273    0.7273
   0.2727    0.2727
```

# Questões ?

- Converge ?
- Para quê ?

# Equilíbrio

- As cadeias dos nossos exemplos atingem um equilíbrio.
- Quando isso acontece a probabilidade de qualquer estado torna-se constante independentemente do passo (step) e das condições iniciais
- Para analisar essa situação é necessário considerar um certo tipo de cadeias de Markov…

# Matriz/ Processo regular

- A matriz de transição (ou o processo de Markov correspondente) é **regular** se alguma potência da matriz tem todos os valores não-nulos.
  - Existe uma probabilidade de mudar de qualquer estado para qualquer estado

- Qualquer matriz de transição sem elementos nulos é uma matriz regular.
- No entanto, uma matriz contendo elementos nulos pode ser regular.
  - Por exemplo: $T = \begin{bmatrix} 0 & 0 & 0.5 \\ 1 & 0 & 0.5 \\ 0 & 1 & 0 \end{bmatrix}$

…

- No caso de matrizes com elementos nulos, pode verificar-se se é regular substituindo os elementos não-nulos por “X” e calculando potências sucessivas

- No nosso exemplo:
- $T = \begin{bmatrix} 0 & \mathrm{X} & 0 \\ 0 & 0 & \mathrm{X} \\ \mathrm{X} & \mathrm{X} & 0 \end{bmatrix}, T^2 = \begin{bmatrix} 0 & 0 & \mathrm{X} \\ \mathrm{X} & \mathrm{X} & 0 \\ 0 & \mathrm{X} & \mathrm{X} \end{bmatrix} \ldots, T^8 = \begin{bmatrix} \mathrm{X} & \mathrm{X} & \mathrm{X} \\ \mathrm{X} & \mathrm{X} & \mathrm{X} \\ \mathrm{X} & \mathrm{X} & \mathrm{X} \end{bmatrix}$

# Cadeia **ergódica**

- Uma cadeia de Markov diz-se ergódica se é possível efectuar transições de qualquer estado para qualquer outro estado

- Em consequência, uma cadeia regular é também ergódica

# Cadeia ergódica

- No entanto, nem todas as cadeias ergódicas são regulares
  - Exemplo: se de um determinado estado se pode transitar para alguns estados apenas num número par de transições e para outros num número ímpar de transições, então todas as potências da matriz de transição terão elementos nulos

$$T = \begin{bmatrix} 0 & 0.5 & 0 \\ 1 & 0 & 1 \\ 0 & 0.5 & 0 \end{bmatrix}$$

...

- Potências pares

```
>> T^30

ans =

    0.5000         0    0.5000
         0    1.0000         0
    0.5000         0    0.5000

>> T^100

ans =

    0.5000         0    0.5000
         0    1.0000         0
    0.5000         0    0.5000
```

- Potências ímpares

```
>> T^5
ans =

         0    0.5000         0
    1.0000         0    1.0000
         0    0.5000         0

>> T^51

ans =

         0    0.5000         0
    1.0000         0    1.0000
         0    0.5000         0
```

# $\lim_{n\to\infty} T^n$

- Se $T$ é a matriz de transição de um processo de Markov regular então:
- $\lim_{n\to\infty} T^n$ é a matriz:

$$A = \begin{bmatrix} u_1 & u_1 & \cdots & u_1 \\ u_2 & u_2 & \cdots & u_2 \\ \cdots & \cdots & \cdots & \cdots \\ u_N & u_N & \cdots & u_N \end{bmatrix}$$

Com todas as colunas idênticas

- Cada coluna **u** é um vector probabilidade em que todas as componentes são positivas

# Vector estado estacionário (steady-stade vector)

- Sendo $T$ uma matriz de transição regular e A e $\mathbf{u}$ o resultado de $\lim_{n\to\infty} T^n$ (slide anterior), demonstra-se que:

a) Para qualquer vector de probabilidade $\mathbf{x}$, $\boldsymbol{T^n}\,\mathbf{x} \rightarrow \mathbf{u}$ quando $n \rightarrow \infty$

Sendo $\mathbf{u}$ o vector estado estacionário (**steady-state vector**)

**b)** $\mathbf{u}$ é o único vector de probabilidade que satisfaz a equação matricial $\mathbf{Tu} = \mathbf{u}$

**c)** $\lim_{\boldsymbol{n}\to\infty}\left(\frac{\boldsymbol{\eta(i,n)}}{\boldsymbol{n}}\right) = \boldsymbol{u(i)}$, em que $\eta(i,n)$ é o número de visitas ao estado ***i*** em ***n*** passos (transições)

# Cálculo do vector estado estacionário

- Sabemos que o vector correspondente ao estado estacionário é único.
- Usamos a equação que ele satisfaz para o calcular: $\mathbf{Tu} = \mathbf{u}$

- Ou, na forma matricial, $(\mathbf{T} - \mathbf{I})\mathbf{u} = 0$

# Exemplo 1 (aulas)

- $\mathbf{Tu} = \mathbf{u}$
- $\begin{bmatrix} 0,7 & 0,8 \\ 0,3 & 0,2 \end{bmatrix} \begin{bmatrix} u_1 \\ u_2 \end{bmatrix} = \begin{bmatrix} u_1 \\ u_2 \end{bmatrix}$
- $\begin{cases} \frac{7}{10} u_1 + \frac{8}{10} u_2 = u_1 \\ \frac{3}{10} u_1 + \frac{2}{10} u_2 = u_2 \\ u_1 + u_2 = 1 \end{cases} = \begin{cases} \frac{-3}{10} u_1 + \frac{8}{10} u_2 = 0 \\ \frac{3}{10} u_1 + \frac{-8}{10} u_2 = 0 \\ u_1 + u_2 = 1 \end{cases}$
- …

# Em Matlab

Uma possível solução:

```
% matriz de transição
T=[7 8; 3 2]/10
% (T-I)u aumentado com u1+u2
M=[T-eye(2);
  ones(1,2)]
%
x=[0 0 1]'
% resolver para obter u
u=M\x
```

Resultado:

0.7273

0.2727

Ou seja aprox. 72 % de probabilidade de não faltarem

Exemplo1.m

# Outra possibilidade

```
%  matriz de transição
T=[7 8; 3 2]/10;

% resolver equação Au= b
aux= (T-eye(length(T)));

% usas as primeiras linhas de T + equação x1+x2= 1
A= [aux(1:end-1,:); 1 1];

b= [0 1]';

u= inv(A)*b
```

…

- Pode também ser resolvido usando uma matriz aumentada e a função **rref**()

```
%Matlab
C= [M   x]
rref(C)
```

$$\left(\begin{array}{cc|c} -3/10 & 8/10 & 0 \\ 3/10 & -8/10 & 0 \\ 1 & 1 & 1 \end{array}\right) \rightsquigarrow \left(\begin{array}{cc|c} 1 & 0 & 8/11 \\ 0 & 1 & 3/11 \\ 0 & 0 & 0 \end{array}\right)$$

- Mais informação: [https://www.math.ucdavis.edu/~daddel/MATH22AL/LABS/LAB2/lab2.pdf](https://www.math.ucdavis.edu/~daddel/MATH22AL/LABS/LAB2/lab2.pdf)

# Exemplo 2

- Aplicando a última técnica ao nosso exemplo 2 (grupos) teremos

$$\left(\begin{array}{rrr|r} -2/3 & 1/4 & 0 & 0 \\ 1/3 & -1/2 & 1/2 & 0 \\ 1/3 & 1/4 & -1/2 & 0 \\ 1 & 1 & 1 & 1 \end{array}\right) \rightsquigarrow \left(\begin{array}{rrr|r} 1 & 0 & 0 & 3/17 \\ 0 & 1 & 0 & 8/17 \\ 0 & 0 & 1 & 6/17 \\ 0 & 0 & 0 & 0 \end{array}\right)$$

# Cadeias com estados absorventes

# Estados absorventes

- Um **estado absorvente** é um estado do qual não é possível sair (ou seja transitar para outro estado)

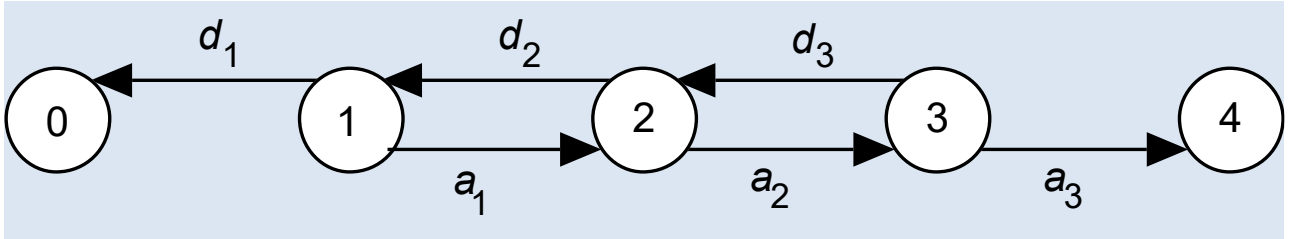


- Os estados 0 e 4 são absorventes

# Cadeias absorventes

- Uma **cadeia** é **absorvente** se:

(1) tiver pelo menos um estado absorvente

(2) é possível ir de cada um dos estados não absorventes para pelo menos um dos estados absorventes num número finito de passos.

# Exemplo simples

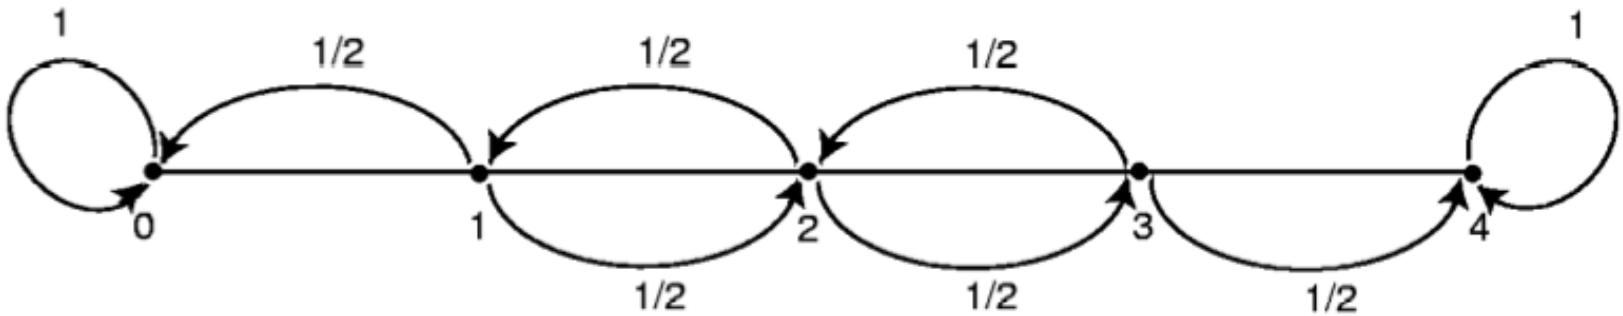

# Demo

- Absorbing  Markov Chain
  - http://demonstrations.wolfram.com/AbsorbingMarkovChain/