MPECI 2025-2026

Desempenho de Servidores

Serviços baseado num único servidor

Recursos de um servidor:

- Capacidade de processamento: processador(es) + memória RAM
- Capacidade *C* da sua ligação à rede

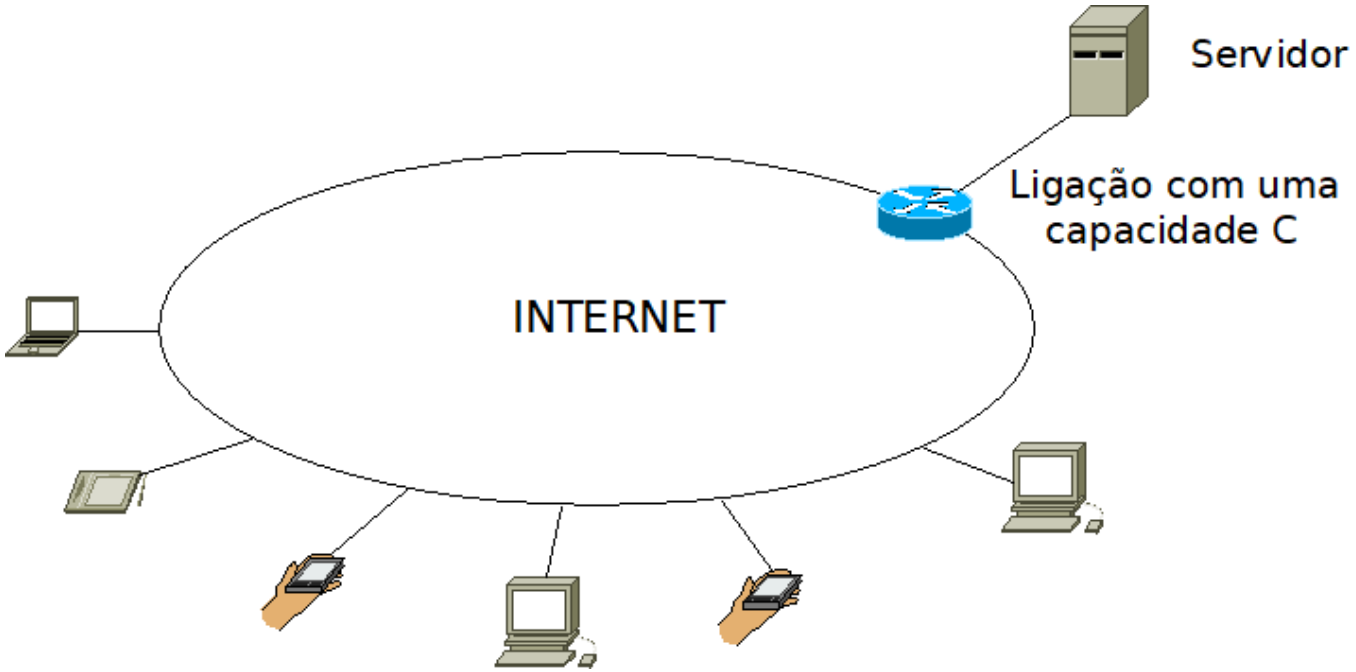

Tipos de serviços

O desempenho de um servidor depende do tipo de serviço disponibilizado pelo servidor.

O tipo de serviço determina de que forma os recursos do servidor são usados e que recursos limitam o seu desempenho:

- serviços que requerem maioritariamente recursos de rede e, portanto, o seu desempenho é limitado pela capacidade *C* da ligação do servidor à rede
- serviços que requerem maioritariamente recursos de processamento e, portanto, o seu desempenho é limitado pela capacidade de processamento do servidor

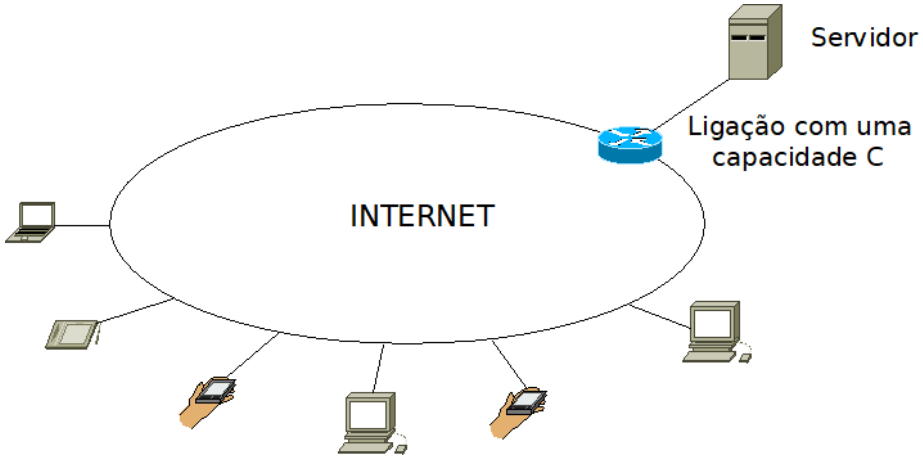

Tipos de serviços

Neste módulo, vamos endereçar o desempenho de 3 tipos de serviços:

- serviços de *video-streaming*, cujo desempenho está limitado pela capacidade *C* da ligação do servidor à rede
- serviços de dados, cujo desempenho está limitado pela capacidade de processamento do servidor
- serviços do tipo *Call Center*, cujo desempenho está limitado pelo número disponível de operadores

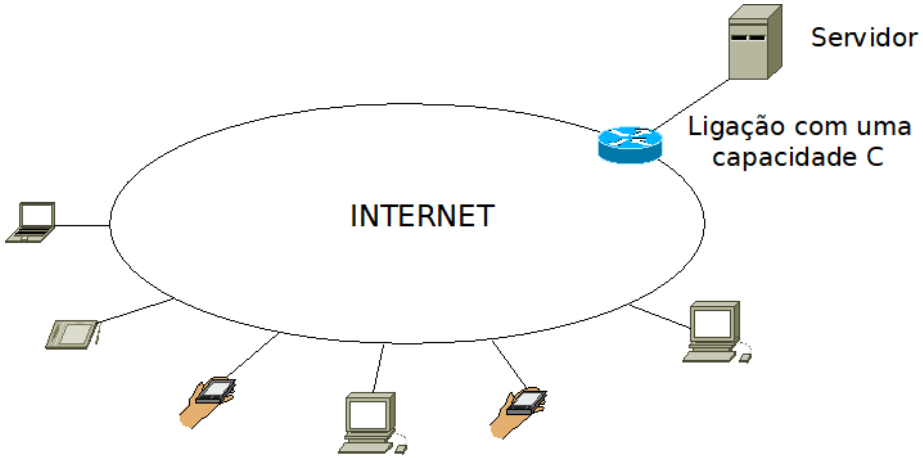

Serviços de *video-streaming*

- Serviços de *video-streaming* (por exemplo, Netflix, HBO Max, Disney+, etc.) providenciam aos seus utilizadores catálogos de filmes, séries e documentários
- O tempo de serviço de cada pedido é caracterizado pela duração do item pedido pelo utilizador
- Cada item requer um débito binário significativo durante a sua transmissão
- A capacidade *C* da ligação é muito mais limitativa do que a capacidade de processamento do servidor

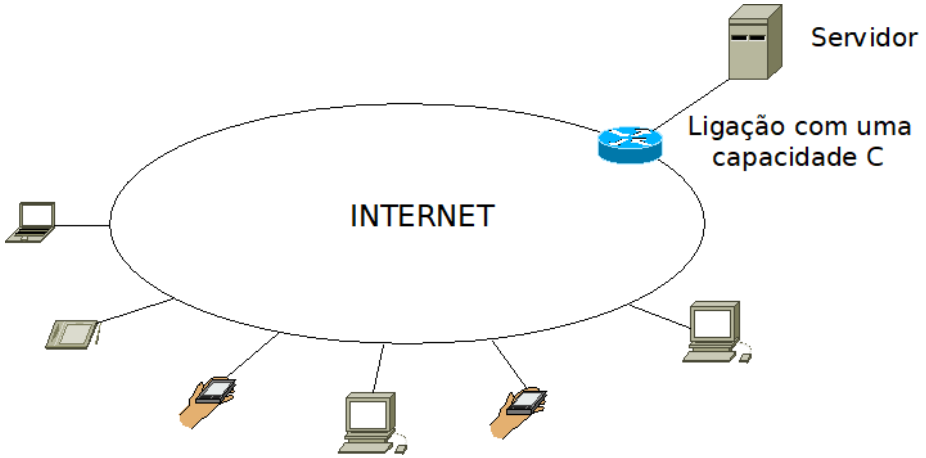

Desempenho de um servidor de *video-streaming*

Se considerarmos que:

- a chegada de pedidos de filmes é um processo de Poisson com taxa λ
- a duração dos filmes é exponencialmente distribuída de média $1/\mu$
- os filmes são codificados num único formato cuja transmissão tem um débito binário B bps
- sendo a capacidade da ligação C bps, então a capacidade do servidor (em no. máximo de filmes que consegue transmitir em simultâneo) é $m = \lfloor C/B \rfloor$
- os pedidos são bloqueados (i.e., recusados) se o servidor estiver a transmitir m filmes (i.e., não existe fila de espera)

Então o servidor pode ser modelado por um sistema *M*/*M*/*m*/*m*

- o estado *n* (*n*= 0,1,…., *m*) representa o número de filmes em transmissão

Desempenho de um servidor de *video-streaming*

Num sistema *M*/*M*/*m*/*m*

- Processo de nascimento e morte:

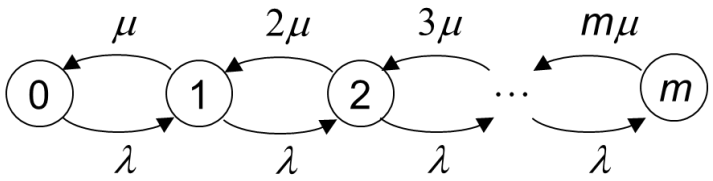

- Probabilidade de cada estado: $$\pi_n = \frac{\left(\frac{\lambda}{\mu}\right)^n / n!}{\sum_{i=0}^{m}\left(\left(\frac{\lambda}{\mu}\right)^i / i!\right)} \quad , n = 0,1,2,\ldots,m$$

- Probabilidade de bloqueio do serviço (fórmula de ErlangB): $$\pi_m = \frac{\left(\frac{\lambda}{\mu}\right)^m / m!}{\sum_{i=0}^{m}\left(\left(\frac{\lambda}{\mu}\right)^i / i!\right)}$$

- No. médio de filmes em transmissão: $$L = \sum_{n=0}^{m}(n \times \pi_n)$$

- Débito binário médio do servidor: $$B_S = B \times L$$

Desempenho de um servidor de *video-streaming*

- No caso geral, os filmes são codificados em diferentes formatos de codificação:
  - cada formato providencia uma qualidade audiovisual diferente e com um débito binário diferente
  - formatos com melhor qualidade audiovisual requerem maiores débitos binários de transmissão
- A cadeia de Markov que modela o caso geral não é um processo de nascimento e morte simples:
  - cada estado necessidade de identificar o número de filmes de cada formato que estão em transmissão
- Esta situação é ilustrada no Exemplo 1 seguinte.

Exemplo 1

Considere um servidor de *video-streaming* com uma interface de rede de 10 Mbps e com todos os filmes do seu catálogo disponíveis em formato standard (2.0 Mbps) e HD (4.0 Mbps).

No período de maior tráfego, a taxa de pedidos de filmes é de 2 pedidos/hora de filmes em formato standard e 1 pedido/hora de filmes em formato HD. Os filmes têm uma duração exponencialmente distribuída de média 90 minutos.

Quando um filme é pedido, ele começa a ser transmitido se houver capacidade disponível na interface de rede ou é recusado caso contrário.

Taxas de transição:

λ_1 = 2 horas^{-1} (taxa de chegada para o formato standard)

λ_2 = 1 horas^{-1} (taxa de chegada para o formato HD)

$1/\mu$ = 90 min = 3/2 horas (igual para os 2 formatos)

$\mu_1 = \mu_2$ = 2/3 horas^{-1} (taxa de partida de cada filme)

Cadeia de Markov do Exemplo 1
(Diagrama de Transição de Estados)

Estados: ij

i - nº de filmes em formato standard em transmissão

j - nº de filmes em formato HD em transmissão

$B_{ij} \rightarrow 2 \times i + 4 \times j$ capacidade da ligação ocupada pelo estado ij

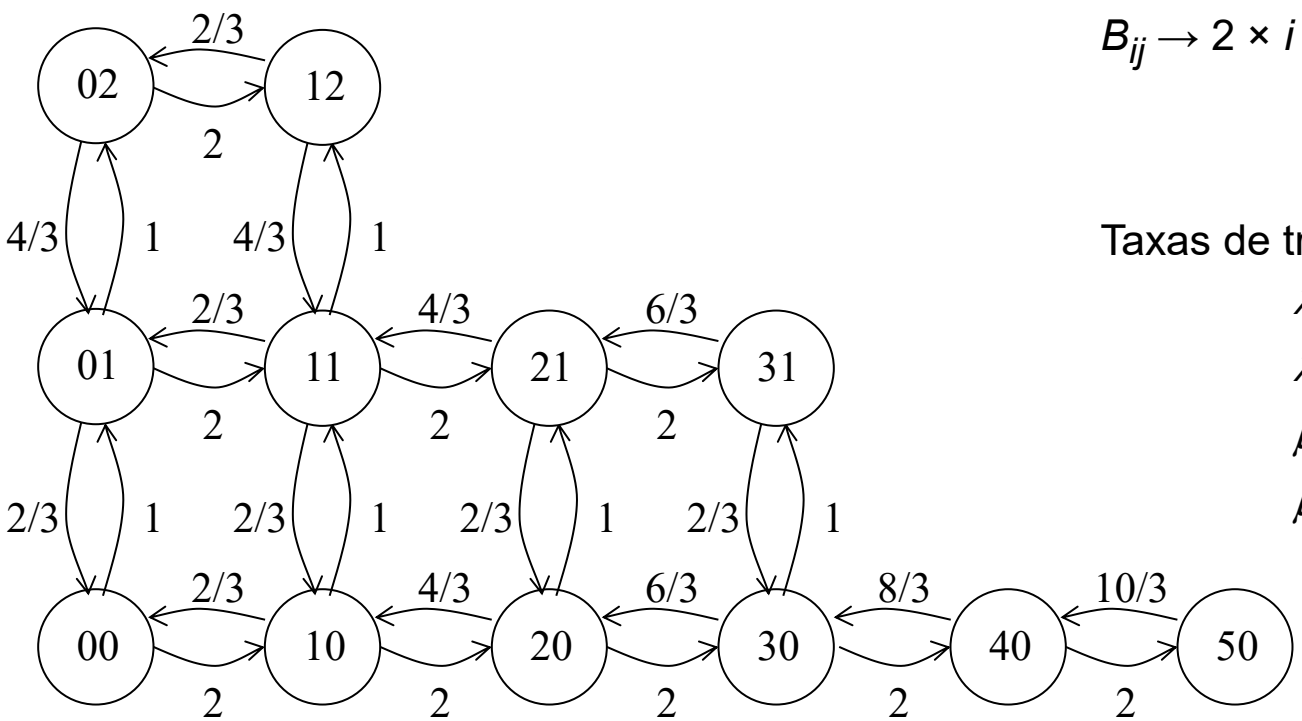

Taxas de transição:

$\lambda_1 = 2$ horas^{-1}

$\lambda_2 = 1$ horas^{-1}

$\mu_1 = 2/3$ horas^{-1}

$\mu_2 = 2/3$ horas^{-1}

Exemplo 1 – resolução matricial no MATLAB

```
M= [-3    2/3      0        0        0        0       2/3      0        0        0        0        0
     2    -3-2/3   4/3      0        0        0       0        2/3      0        0        0        0
     0    2        -3-4/3   6/3      0        0       0        0        2/3      0        0        0
     0    0        2        -3-6/3   8/3      0       0        0        0        2/3      0        0
     0    0        0        2        -2-8/3   -10/3   0        0        0        0        0        0
     0    0        0        0        2        10/3    0        0        0        0        0        0
     1    0        0        0        0        0       -3-2/3   2/3      0        0        4/3      0
     0    1        0        0        0        0       2        -3-4/3   4/3      0        0        4/3
     0    0        1        0        0        0       0        2        -2-6/3   6/3      0        0
     0    0        0        1        0        0       0        0        2        -8/3     0        0
     0    0        0        0        0        0       1        0        0        0        -2-4/3   2/3
     0    0        0        0        0        0       0        1        0        0        2        -6/3
     1    1        1        1        1        1       1        1        1        1        1        1]
```

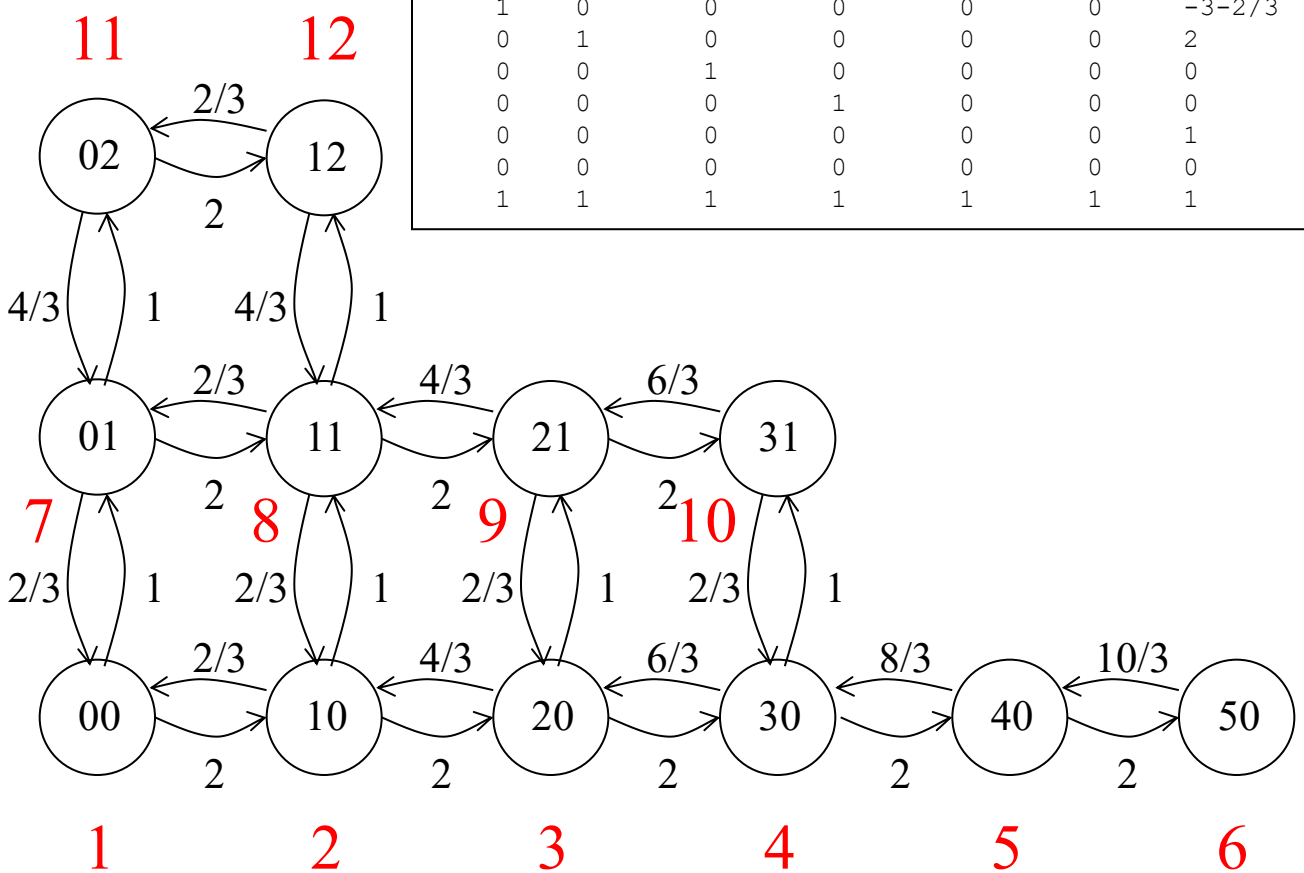


```
x= [0
    0
    0
    0
    0
    0
    0
    0
    0
    0
    0
    0
    1]
```

Exemplo 1 – resolução no MATLAB

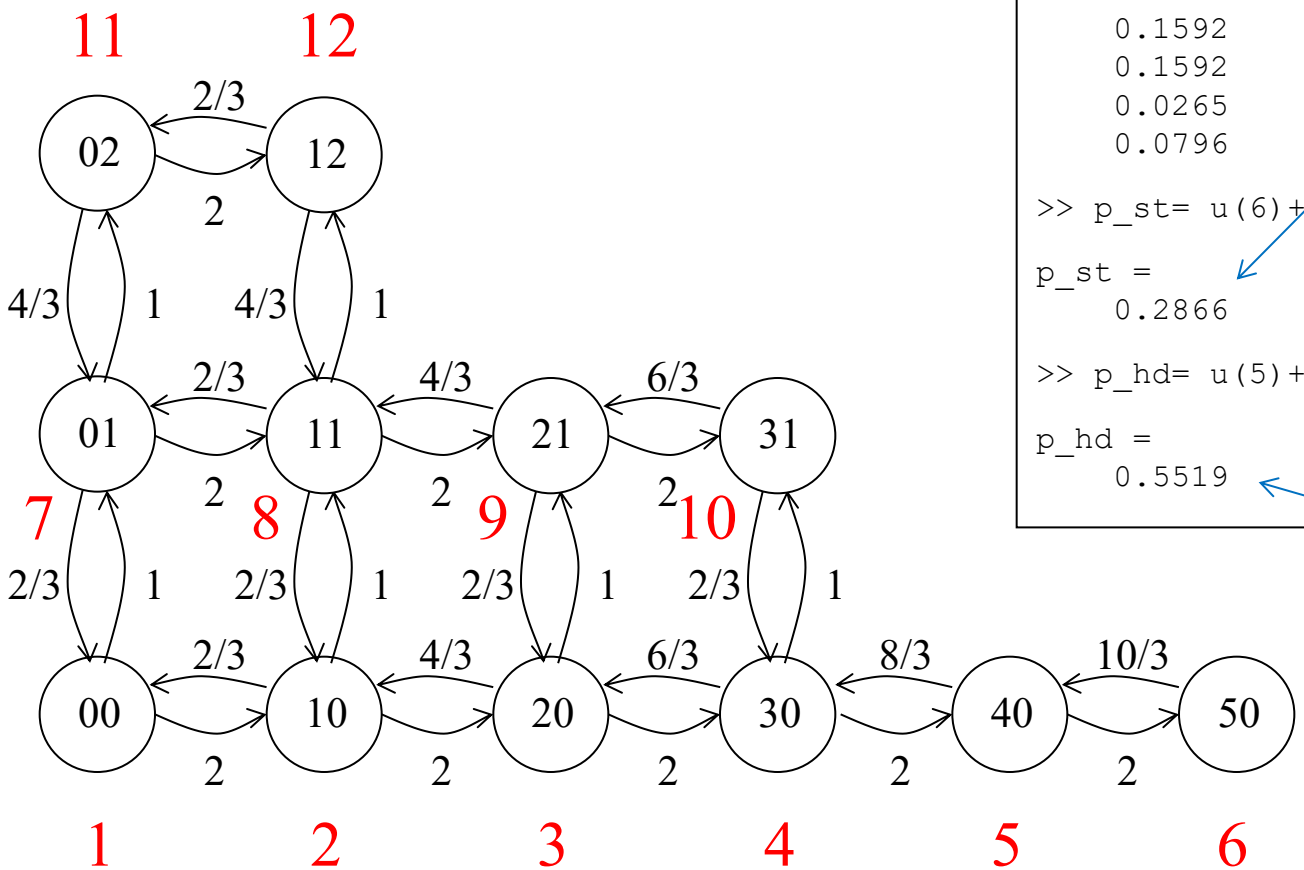


```
>> u=M\x

u =
    0.0236
    0.0708
    0.1061
    0.1061
    0.0796
    0.0478
    0.0354
    0.1061
    0.1592
    0.1592
    0.0265
    0.0796

>> p_st= u(6)+u(10)+u(12)

p_st =
    0.2866

>> p_hd= u(5)+u(6)+u(9)+u(10)+u(11)+u(12)

p_hd =
    0.5519
```

Bloqueio dos filmes em formato standard

Bloqueio dos filmes em formato HD

Desempenho de um servidor de *video-streaming*

- No caso geral, a cadeia de Markov pode tornar-se demasiado grande. No exemplo anterior (Exemplo1):
  - se a capacidade de ligação for C = 1 Gbps (em vez de 10 Mbps), o número de estados passa de 12 para aproximadamente 6300
  - apenas consideramos 2 formatos de codificação mas o número do formatos possíveis é maior (cada um adequado para diferentes tipos de terminais)
    - HD (High Definition): imagem de 1280 x 720 pixels (< 1 megapixel)
    - FHD (Full HD): imagem de 1920 x 1080 píxeis (2.07 megapixeis)
    - UHD (Ultra HD): imagem de 3840 x 2160 pixeis (8.29 megapixeis)
    - 4K: resolução de imagem de 4096 x 2160 pixéis (8.85 megapixeis)
  - O formato pedido é tipicamente o que mais se adequa ao terminal em uso (smartphone, tablet, smart TV, etc…)
- Para podermos estimar o desempenho destes casos, é necessário considerar uma aproximação.

Desempenho de um servidor de *video-streaming*

- Uma aproximação possível para lidar com o caso geral é:
  - considerar um único formato com um débito binário dado pela média pesada dos débitos dos diferentes formatos (usando como pesos as taxas de pedidos de cada formato);
  - usar o sistema *M*/*M*/*m*/*m* assumindo o formato único.

- Se cada filme estiver disponível em *F* formatos, em que a cada formato *i* (com *i* = 1, 2, …, *F*) está associado:
  - uma taxa de pedidos de filmes de λ_i
  - um débito binário de B_i
- Então o servidor pode ser modelado por um *M*/*M*/*m*/*m* em que
  - a taxa de chegada de pedidos é: $\lambda = \sum_{i=1}^{F} \lambda_i$
  - o débito binário de cada filme é: $B = \frac{\sum_{i=1}^{F} \lambda_i B_i}{\sum_{i=1}^{F} \lambda_i}$

Exemplo 2

Considere um servidor de *video-streaming* com uma interface de rede de 100 Mbps e com todos os filmes disponíveis em formato standard (2.0 Mbps) e HD (4.0 Mbps).

A taxa de pedidos de filmes é de λ_1 pedidos/hora (filmes em formato standard) e λ_2 pedidos/hora (filmes em formato HD). Os filmes têm uma duração exponencialmente distribuída de média 90 minutos.

PB1: probabilidade de bloqueio de filmes em formato standard

PB2: probabilidade de bloqueio de filmes em formato HD

PBa: probabilidade de bloqueio do servidor no método aproximado

λ_1	λ_2	PB1	PB2	PBa
6	4	0.0006%	0.0016%	0.0004%
5	5	0.0029%	0.0074%	0.0023%
4	6	0.0101%	0.0254%	0.0107%
3	7	0.0283%	0.0692%	0.0442%

Serviços de *video-streaming*

Se a probabilidade de bloqueio de um servidor com uma ligação de capacidade *C* for demasiado alta, o que fazer?

Alternativas:

Atualizar a capacidade da ligação para *C'*, com *C'* > *C*

- Desempenho modelado por um *M/M/m/m, com* $m = \lfloor C'/B \rfloor$

Proporcionar o serviço com *k* servidores

- Considerando que os pedidos de filmes são servidos por qualquer servidor com capacidade disponível, desempenho modelado por um *M/M/m/m, com* $m = k \times \lfloor C/B \rfloor$

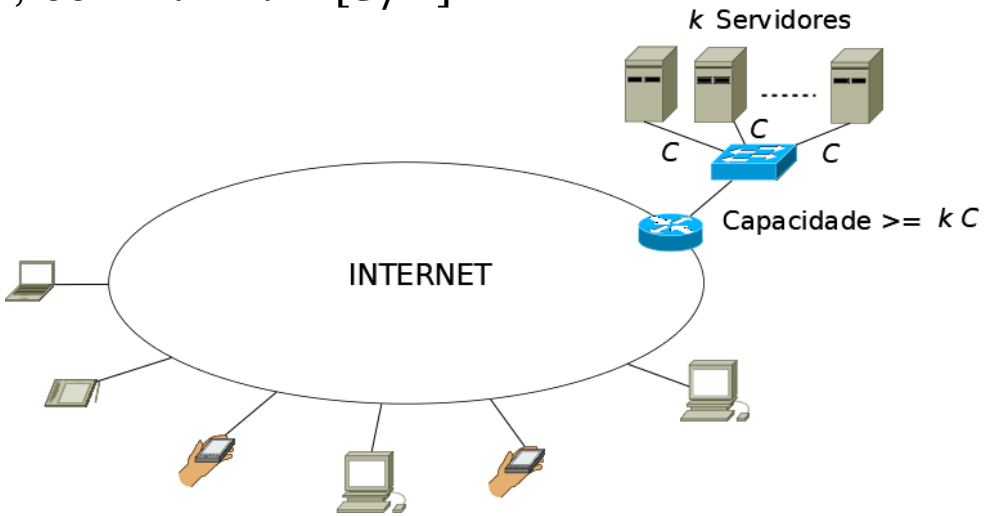

Serviços de dados

- Os serviços de dados são o tipo de serviço mais comum, tais como o acesso a sites baseados em servidores Web
- Este tipo de serviços é caracterizado por exigir do servidor uma utilização significativa dos seus recursos de processamento (CPU, RAM) para compor a resposta a cada pedido de serviço
- Nestes casos, a determinação de cada resposta é dependente da capacidade de processamento do servidor (quanto maior a capacidade de processamento, mais rápida é a resposta) e o débito binário de transmissão de cada resposta não é significativo
- Assim, a capacidade de processamento é muito mais limitativa que a capacidade da ligação *C*

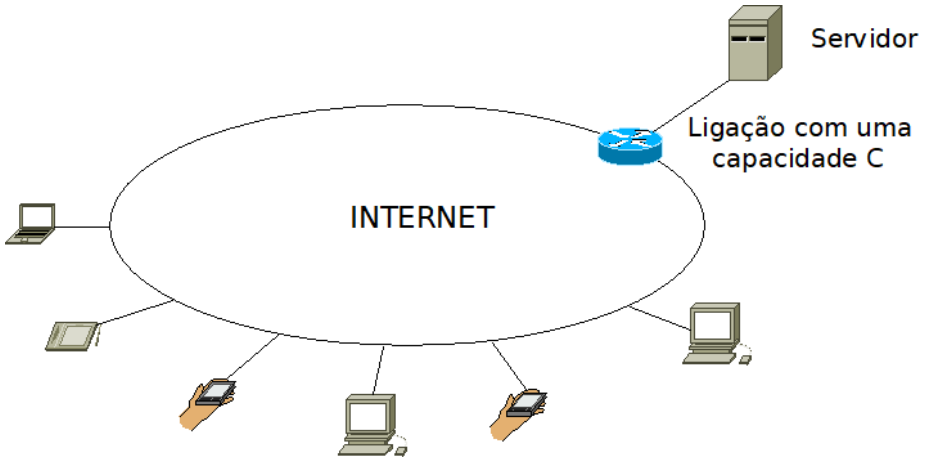

Desempenho de um servidor de um serviço de dados

- Em serviços de dados, o desempenho do servidor é limitado pela sua capacidade de processamento.
  - Por exemplo, um servidor Web pode receber milhares de pedidos HTTP por dia cujo tempo de resposta por pedido pode tornar-se demasiado grande se o número de pedidos em processamento for muito grande.
- Para evitar esta situação:
  - através de testes de stress, determina-se um tempo médio de serviço por pedido $1/\mu$ para um número *m* de pedidos simultâneos em processamento,
  - se o valor $1/\mu$ for adequado, o servidor é configurado para recusar os pedidos que chegam quando está a processar *m* pedidos simultâneos.
- O servidor serve os pedidos à sua capacidade máxima e dividindo igualmente os seus recursos pelos pedidos em processamento:
  - Disciplina *PS* (*Processor Sharing*): cada pedido recebe um tempo de serviço que é suspenso até que todos os outros pedidos recebam o mesmo tempo de serviço

Desempenho de um servidor de um serviço de dados

- Este sistema pode ser modelado por um sistema *M*/*M*/1/*m***PS*:

  (1) a chegada de clientes é um processo de Poisson com taxa λ

  (2) o sistema tem 1 servidor

  (3) o servidor atende até *m* clientes

  (4) o sistema tem capacidade de *m* clientes (i.e., não tem fila de espera)

  (5) o servidor atende os clientes com um tempo exponencialmente distribuído por cliente de $n/m\mu$ em que *n* é o número de clientes no sistema

- Na notação *M*/*M*/1/*m***PS*, o termo '*m***PS*' significa que o servidor pode atender até *m* clientes em simultâneo e atende os clientes segundo uma disciplina *Processor Sharing*.

- A característica (5) significa que o tempo de atendimento é tanto maior quanto maior for o número de clientes no sistema

Sistema *M*/*M*/*m*/*m* vs. Sistema *M*/*M*/1/*m**PS

Sistema M/M/m/m:

- existem *m* servidores,
- cada servidor atende um cliente à taxa μ
- no estado *n*, (*n* = 1,…,*m*), cada um dos *n* clientes é atendido à taxa μ

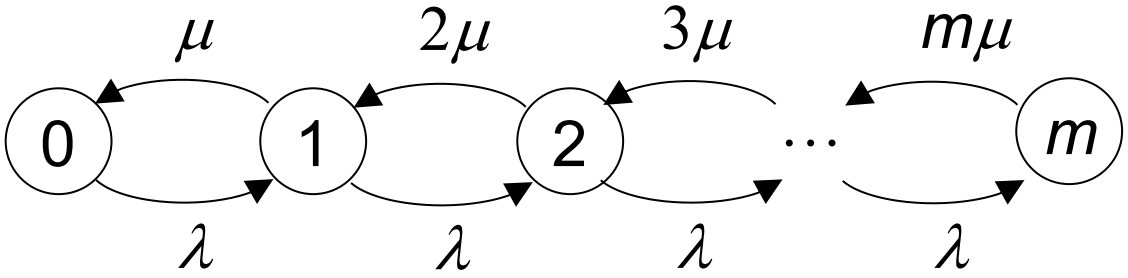

Sistema M/M/1/m*PS:

- existe 1 servidor com capacidade para atender até *m* clientes,
- o servidor atende clientes à taxa $m\mu$ qualquer que seja o no. de clientes
- no estado *n*, (*n* = 1,…,*m*), cada um dos *n* clientes é atendido à taxa $m\mu/n$

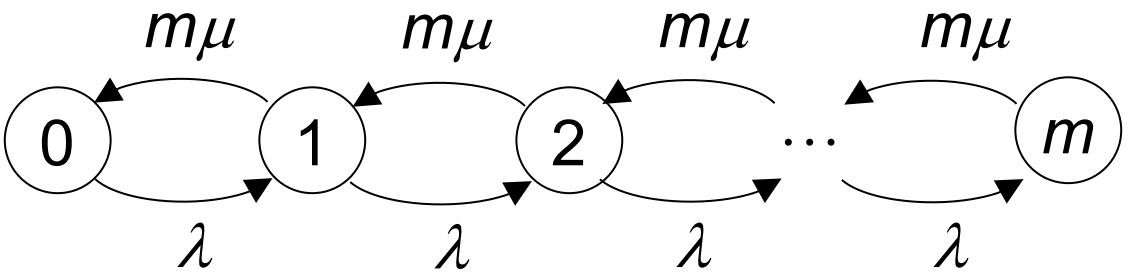

Sistema *M*/*M*/1/*m**PS*

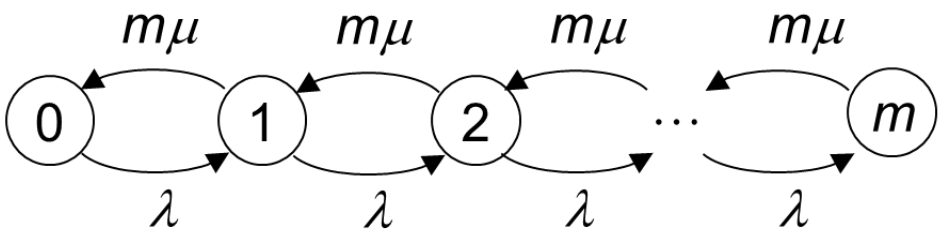

Probabilidade de *n* clientes no sistema em estado estacionário:

$$\pi_n = \frac{\left(\frac{\lambda}{m\mu}\right)^n}{\sum_{i=0}^{m}\left(\frac{\lambda}{m\mu}\right)^i} \qquad , n = 0,1,2,\dots,m$$

Ou por manipulação algébrica:

$$\pi_n = \frac{(1-\rho)}{(1-\rho^{m+1})} \times \rho^n \quad , n = 0,1,2,\dots,m$$

Se $\frac{\lambda}{m\mu} < 1$ e considerando $\rho = \frac{\lambda}{m\mu}$

Pela propriedade PASTA, a probabilidade de um cliente chegar e encontrar o sistema cheio é igual à probabilidade do estado *m*:

$$\pi_m = \frac{\left(\frac{\lambda}{m\mu}\right)^m}{\sum_{i=0}^{m}\left(\frac{\lambda}{m\mu}\right)^i} \qquad \text{ou} \qquad \pi_m = \frac{(1-\rho)}{(1-\rho^{m+1})} \times \rho^m$$

Exemplo 3

Considere um servidor de dados com uma capacidade para atender até 4 pedidos de serviço e que na sua capacidade máxima atende cada pedido com um tempo de serviço exponencialmente distribuído de média 2 milissegundos. Quando os pedidos de serviço chegam a uma taxa de 800 pedidos/segundo, queremos saber:

a) a percentagem de pedidos recusados

$$\pi_n = \frac{(1-\rho)}{(1-\rho^{m+1})} \times \rho^n \quad , n = 0,1,2,\dots,m$$

λ = 800 pedidos/seg

$1/\mu = 2\times10^{-3}$ seg

μ = 500 pedidos/seg

$m = 4$

$$\rho = \frac{\lambda}{m\mu} = \frac{800}{4 \times 500} = 0.4$$

$$\pi_4 = \frac{(1-0.4)}{(1-0.4^5)} \times 0.4^4 = 0.0155$$

R: a percentagem de pedidos recusados é 1.55%

Exemplo 3

Considere um servidor de dados com uma capacidade para atender até 4 pedidos de serviço e que na sua capacidade máxima atende cada pedido com um tempo de serviço exponencialmente distribuído de média 2 milissegundos. Quando os pedidos de serviço chegam a uma taxa de 800 pedidos/segundo, queremos saber:

b) o número médio de pedidos em processamento do servidor

λ = 800 pedidos/seg

μ = 500 pedidos/seg

m = 4

$$\pi_n = \frac{(1-\rho)}{(1-\rho^{m+1})} \times \rho^n \quad , n = 0,1,2,\dots,m$$

$$\rho = \frac{\lambda}{m\mu} = \frac{800}{4 \times 500} = 0.4$$

$$L = \sum_{n=0}^{4} n \times \pi_n = \frac{(1-\rho)}{(1-\rho^5)}(\rho + 2\rho^2 + 3\rho^3 + 4\rho^4)$$

$$= \frac{(1-0.4)}{(1-0.4^5)}(0.4 + 2 \times 0.4^2 + 3 \times 0.4^3 + 4 \times 0.4^4) = 0.6149$$

R: o número médio de pedidos em processamento é 0.6149

Exemplo 3

Considere um servidor de dados com uma capacidade para atender até 4 pedidos de serviço e que na sua capacidade máxima atende cada pedido com um tempo de serviço exponencialmente distribuído de média 2 milissegundos. Quando os pedidos de serviço chegam a uma taxa de 800 pedidos/segundo, queremos saber:

c) o tempo médio de serviço de cada pedido

λ = 800 pedidos/seg

μ = 500 pedidos/seg

m = 4

$$\rho = \frac{\lambda}{m\mu} = \frac{800}{4 \times 500} = 0.4$$

Teorema de Little

$$W = \frac{L}{\lambda(1 - \pi_4)}$$

Resultado de b)

$$W = \frac{0.6149}{800 \times (1 - 0.0155)} = 7.81 \times 10^{-4} \text{ seg.}$$

Resultado de a)

R: o tempo médio de serviço é 0.781 mseg. (NOTA: 2 mseg. é o tempo médio de serviço quando o servidor está a atender 4 clientes em simultâneo)

Desempenho de um servidor de um serviço de dados

- Conforme enunciado anteriormente:
  - através de testes de stress, determina-se um tempo médio de serviço por pedido $1/\mu$ para um número *m* de pedidos simultâneos em processamento,
  - se o valor $1/\mu$ for adequado, o servidor é configurado para recusar os pedidos que chegam quando ele está a processar *m* pedidos simultâneos.
- No caso geral, o servidor pode ser configurado para recusar os pedidos que chegam quando ele está a processar um número de pedidos simultâneos *b* diferente de *m:*
  - se o tempo médio de serviço por pedido $1/\mu$ puder ser maior (i.e., pior), *b* pode ser maior que *m* (melhorando a taxa de pedidos recusados)
  - se o tempo médio de serviço por pedido $1/\mu$ for demasiado grande, *b* tem de ser menor que *m* (melhorando o tempo médio de serviço por pedido quando o servidor está a atender à sua capacidade máxima).

Sistema *M*/*M*/1/*b***PS*
(quando b ≠ m)

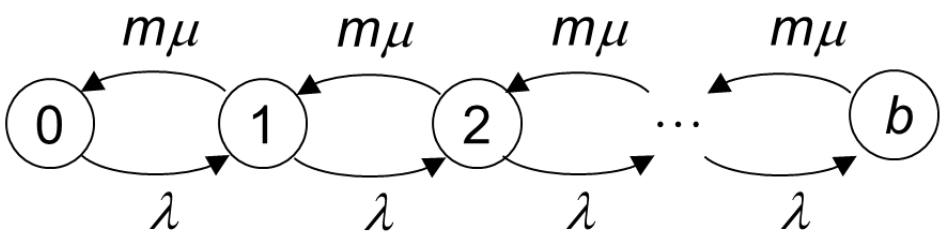

Probabilidade de *n* clientes no sistema em estado estacionário:

$$\pi_n = \frac{\left(\frac{\lambda}{m\mu}\right)^n}{\sum_{i=0}^{b}\left(\frac{\lambda}{m\mu}\right)^i} \quad , n = 0,1,2,\dots,b$$

Ou por manipulação algébrica:

$$\pi_n = \frac{(1-\rho)}{(1-\rho^{b+1})} \times \rho^n \quad , n = 0,1,2,\dots,b$$

Se $\frac{\lambda}{m\mu} < 1$ e considerando $\rho = \frac{\lambda}{m\mu}$

Pela propriedade PASTA, a probabilidade de um cliente chegar e encontrar o sistema cheio é igual à probabilidade do estado *b*:

$$\pi_b = \frac{\left(\frac{\lambda}{m\mu}\right)^b}{\sum_{i=0}^{b}\left(\frac{\lambda}{m\mu}\right)^i} \quad \text{ou} \quad \pi_b = \frac{(1-\rho)}{(1-\rho^{b+1})} \times \rho^b$$

Serviços de dados

Se o desempenho de um único servidor for insuficiente, o que fazer?

Alternativas:

Trocar o servidor por um outro servidor com mais recursos de processamento (CPU, RAM)

- Desempenho modelado por um *M*/*M*/1/*m***PS*

Proporcionar o serviço com *k* servidores

- Desempenho modelado por *k* sistemas *M*/*M*/1/*m***PS* e assumindo que os pedidos são igualmente distribuídos pelos *k* servidores

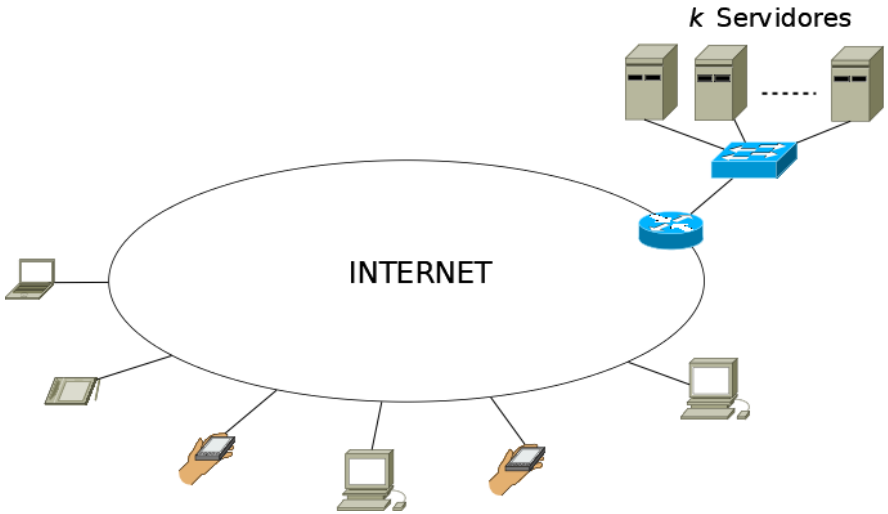

Serviços de dados

- Alternativas (do slide anterior):
  1. Trocar o servidor por um outro servidor com mais recursos de processamento (CPU, RAM)
  2. Proporcionar o serviço com *k* servidores
- Considere-se que o desempenho de um servidor com *k* vezes mais recursos de processamento (CPU, RAM) é *k* vezes melhor (i.e., atende cada pedido com o mesmo tempo médio para um número de pedidos em processamento simultâneo *k* vezes maior):
  - em termos de desempenho, a alternativa 1 é sempre melhor do que a alternativa 2 (ilustrado no Exemplo 4 seguinte),
  - a alternativa 2 é usada na prática quando o custo de múltiplos servidores de menor desempenho é menor que o custo de um único servidor de alto desempenho.
- Em muitos casos, a diferença é maior pois um servidor com *k* vezes mais recursos pode ter um desempenho maior que *k* vezes melhor.

Exemplo 4

Considere-se um serviço de dados cujo tempo de serviço por pedido tem de ser no máximo 2 milissegundos de média. O serviço corre num servidor com este tempo máximo de atendimento quando a sua capacidade é de 10 pedidos em processamento simultâneo. Os pedidos de serviço chegam a uma taxa de 4800 pedidos por segundo.

Qual é a percentagem de pedidos de serviço recusados e o tempo médio de serviço a cada pedido com o serviço disponibilizado:

a) pelo servidor atual

b) por um servidor com o dobro da capacidade (i.e., com a capacidade de 20 pedidos em processamento simultâneo para garantir o tempo máximo de serviço por pedido)

c) por dois servidores iguais ao servidor atual

Exemplo 4

Considere-se um serviço de dados cujo tempo de serviço por pedido tem de ser no máximo 2 milissegundos de média. O serviço corre num servidor com este tempo máximo de atendimento quando a sua capacidade é de 10 pedidos em processamento simultâneo. Os pedidos de serviço chegam a uma taxa de 4800 pedidos por segundo.

Qual é a percentagem de pedidos de serviço recusados e o tempo médio de serviço a cada pedido com o serviço disponibilizado:

a) pelo servidor atual

1 sistema $M/M/1/m*PS$ com os parâmetros:

λ = 4800 pedidos/seg.

$1/\mu = 2\times10^{-3}$ seg.

$m = 10$

Resultados:

Percentagem de pedidos recusados: 7.351%

Tempo médio de serviço: 1.033 mseg.

Exemplo 4

Considere-se um serviço de dados cujo tempo de serviço por pedido tem de ser no máximo 2 milissegundos de média. O serviço corre num servidor com este tempo máximo de atendimento quando a sua capacidade é de 10 pedidos em processamento simultâneo. Os pedidos de serviço chegam a uma taxa de 4800 pedidos por segundo.

Qual é a percentagem de pedidos de serviço recusados e o tempo médio de serviço a cada pedido com o serviço disponibilizado:

b) por um servidor com o dobro da capacidade (i.e., com a capacidade de 20 pedidos em processamento simultâneo para garantir o tempo máximo de serviço por pedido)

1 sistema $M/M/1/m*PS$ com os parâmetros:

λ = 4800 pedidos/seg

$1/\mu = 2\times10^{-3}$ seg.

***m* = 20**

Resultados:

Percentagem de pedidos recusados: 0.000022%

Tempo médio de serviço: 0.192 mseg.

Exemplo 4

Considere-se um serviço de dados cujo tempo de serviço por pedido tem de ser no máximo 2 milissegundos de média. O serviço corre num servidor com este tempo máximo de atendimento quando a sua capacidade é de 10 pedidos em processamento simultâneo. Os pedidos de serviço chegam a uma taxa de 4800 pedidos por segundo.

Qual é a percentagem de pedidos de serviço recusados e o tempo médio de serviço a cada pedido com o serviço disponibilizado:

c) por dois servidores iguais ao servidor atual

2 sistemas *M*/*M*/1/*m***PS* idênticos, cada um com os parâmetros:

λ **= 2400 pedidos/seg.**

$1/\mu = 2\times10^{-3}$ seg.

$m = 10$

Resultados

Percentagem de pedidos recusados: 0.034%

Tempo médio de serviço: 0.383 mseg.

Exemplo 4

Considere-se um serviço de dados cujo tempo de serviço por pedido tem de ser no máximo 2 milissegundos de média. O serviço corre num servidor com este tempo máximo de atendimento quando a sua capacidade é de 10 pedidos em processamento simultâneo. Os pedidos de serviço chegam a uma taxa de 4800 pedidos por segundo.

a) pelo servidor atual

Percentagem de pedidos recusados: 7.351%

Tempo médio de serviço: 1.033 mseg.

b) por um servidor com o dobro da capacidade

Percentagem de pedidos recusados: 0.000022%

Tempo médio de serviço: 0.192 mseg.

c) por dois servidores iguais ao servidor atual

Percentagem de pedidos recusados: 0.034%

Tempo médio de serviço: 0.383 mseg.

CONCLUSÃO: 2 servidores com os mesmos recursos de processamento têm um desempenho pior que 1 servidor com o dobro dos recursos de processamento

Desempenho de um servidor de um serviço do tipo *Call Center*

- Em serviços de tipo *Call Center:*
  - existe um conjunto de *m* operadores para atender clientes
  - quando um pedido de um cliente chega, o pedido:
    - é atribuído a um operador disponível ou
    - é posto em fila de espera se os *m* operadores estiverem ocupados
  - quando um operador fica disponível, é-lhe imediatamente atribuído o pedido em espera mais antigo (i.e., os pedidos em espera são atendidos por ordem de chegada)
  - o tempo de serviço é caracterizado pelo tempo de atendimento de um operador a um cliente
- Assumindo que a chegada de pedidos é um processo de Poisson e que o tempo de atendimento é exponencialmente distribuído, o desempenho do serviço é modelado por um sistema *M*/*M*/*m*.

Sistema *M*/*M*/*m*

- Processo de nascimento e morte em que:
  (1) a chegada de clientes é um processo de Poisson com taxa λ
  (2) o sistema tem *m* servidores
  (3) cada servidor atende um cliente de cada vez com um tempo exponencialmente distribuído de média $1/\mu$
  (4) o sistema acomoda um número infinito de clientes

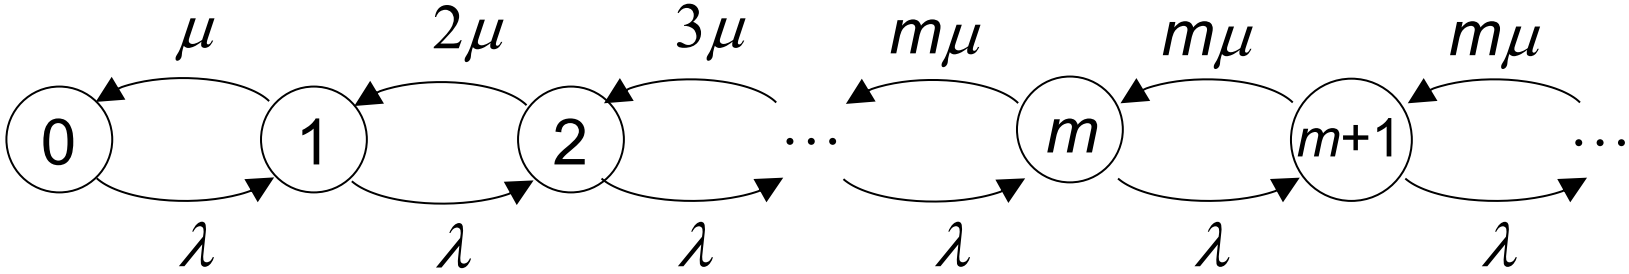

- Nos estados n = 0, 1, …, m, o sistema tem n clientes em atendimento e 0 clientes em espera.
- Nos estados n = m+1, m+2, …, m+i, o sistema tem m clientes em atendimento e i clientes em espera.

Sistema *M*/*M*/*m* (probabilidades limite)

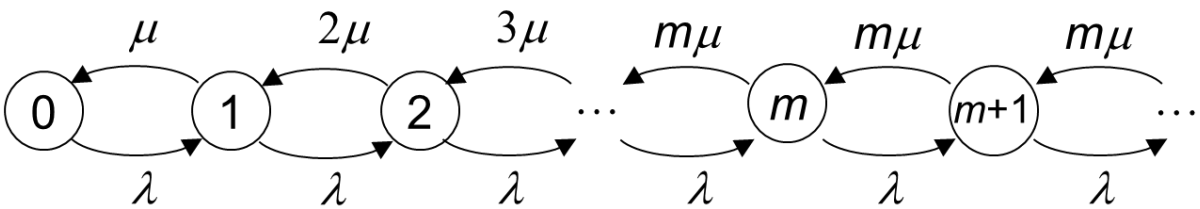

Probabilidades limite de um processo de nascimento e morte

$$\pi_0 = \frac{1}{1 + \sum_{k=1}^{\infty}\left(\frac{\lambda_0\lambda_1 \dots \lambda_{k-1}}{\mu_1\mu_2 \dots \mu_k}\right)} \qquad \pi_n = \frac{\lambda_0\lambda_1 \dots \lambda_{n-1}}{\mu_1\mu_2 \dots \mu_n}\pi_0$$

M/*M*/*m*:

Considerando $\rho = \dfrac{\lambda}{m\mu}$

$$\pi_0 = \frac{1}{\left(\sum_{k=0}^{m-1}\frac{(m\rho)^k}{k!}\right) + \frac{(m\rho)^m}{m!\,(1-\rho)}} \qquad \pi_n = \begin{cases} \dfrac{\frac{(m\rho)^n}{n!}}{\left(\sum_{k=0}^{m-1}\frac{(m\rho)^k}{k!}\right) + \frac{(m\rho)^m}{m!\,(1-\rho)}} & , n \le m \\[2ex] \dfrac{\frac{m^m\rho^n}{m!}}{\left(\sum_{k=0}^{m-1}\frac{(m\rho)^k}{k!}\right) + \frac{(m\rho)^m}{m!\,(1-\rho)}} & , n > m \end{cases}$$

Condição de validade: $\rho = \dfrac{\lambda}{m\mu} < 1$

M/*M*/*m* (alguns parâmetros de desempenho)

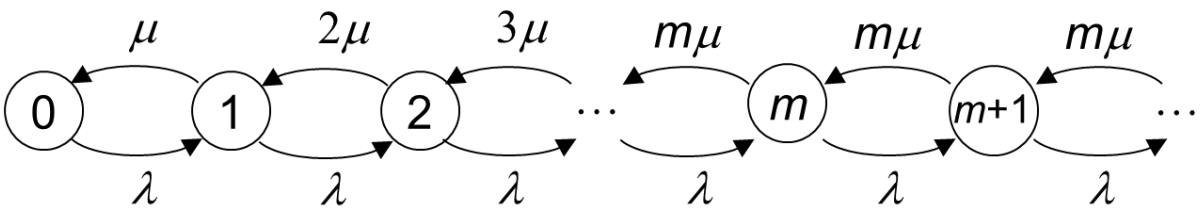

Probabilidades limite do *M*/*M*/*m*

$$\rho = \frac{\lambda}{m\mu}$$

$$\pi_0 = \frac{1}{\left(\sum_{k=0}^{m-1} \frac{(m\rho)^k}{k!}\right) + \frac{(m\rho)^m}{m!\,(1-\rho)}}$$

$$\pi_n = \begin{cases} \dfrac{\dfrac{(m\rho)^n}{n!}}{\left(\sum_{k=0}^{m-1} \frac{(m\rho)^k}{k!}\right) + \frac{(m\rho)^m}{m!\,(1-\rho)}} & ,n \le m \\ \dfrac{\dfrac{m^m \rho^n}{m!}}{\left(\sum_{k=0}^{m-1} \frac{(m\rho)^k}{k!}\right) + \frac{(m\rho)^m}{m!\,(1-\rho)}} & ,n > m \end{cases}$$

Probabilidade de todos os servidores estarem ocupados

$$P_Q = \sum_{n=m}^{+inf} \pi_n = \frac{(m\rho)^m}{m!\,(1-\rho)} \pi_0$$

No. médio de clientes na fila de espera

$$L_Q = \sum_{n=m+1}^{+inf} (n-m) \times \pi_n = \frac{\rho}{(1-\rho)} P_Q$$

Atraso médio de clientes na fila de espera

$$W_Q = \frac{L_Q}{\lambda} = \frac{\rho}{\lambda(1-\rho)} P_Q$$

Exemplo

Um servidor de *Call Center* tem 4 operadores e prevê uma taxa de chegada de 60 pedidos por hora. Cada chamada tem uma duração exponencial de 3 minutos de média. Queremos saber:

a) a probabilidade de um pedido ser imediatamente atendido

$$\pi_0 = \frac{1}{\left(\sum_{k=0}^{m-1} \frac{(m\rho)^k}{k!}\right) + \frac{(m\rho)^m}{m!\,(1-\rho)}}$$

$$P_Q = \frac{(m\rho)^m}{m!\,(1-\rho)}\pi_0 \qquad \rho = \frac{\lambda}{m\mu}$$

λ = 60/60 = 1 pedidos/min

$1/\mu$ = 3 min

μ = 1/3 pedidos/min

m = 4

$$\rho = \frac{\lambda}{m\mu} = \frac{1}{4 \times 1/3} = 0.75$$

$$\pi_0 = \frac{1}{1 + \frac{4 \times 0.75}{1!} + \frac{(4 \times 0.75)^2}{2!} + \frac{(4 \times 0.75)^3}{3!} + \frac{(4 \times 0.75)^4}{4! \times (1 - 0.75)}} = 0.037736$$

$$P_Q = \frac{(4 \times 0.75)^4}{4! \times (1 - 0.75)} \times 0.037736 = 0.5094$$

R: Um pedido é imediatamente atendido com probabilidade $1 - P_Q$ ou seja com probabilidade 49.06%

Exemplo 5

Um servidor de *Call Center* tem 4 operadores e prevê uma taxa de chegada de 60 pedidos por hora. Cada chamada tem uma duração exponencial de 3 minutos de média. Queremos saber:

b) o tempo médio que os clientes esperam na fila de espera

λ = 60/60 = 1 pedidos/min

μ = 1/3 pedidos/min

m = 4

$$\rho = \frac{\lambda}{m\mu} = \frac{1}{4 \times 1/3} = 0.75$$

$$W_Q = \frac{\rho}{\lambda(1-\rho)} P_Q \qquad \rho = \frac{\lambda}{m\mu}$$

Resultado de a)

$$W_Q = \frac{0.75}{1 \times (1 - 0.75)} \times 0.5094 = 1.5282$$

R: Cada cliente está em média 1.53 minutos em espera até começar a ser atendido

Exemplo 5

Um servidor de *Call Center* tem 4 operadores e prevê uma taxa de chegada de 60 pedidos por hora. Cada chamada tem uma duração exponencial de 3 minutos de média. Queremos saber:

c) o número médio de operadores ocupados

λ = 60/60 = 1 pedidos/min

μ = 1/3 pedidos/min

m = 4

$$\rho = \frac{\lambda}{m\mu} = \frac{1}{4 \times 1/3} = 0.75$$

$$\pi_n = \frac{\frac{(m\rho)^n}{n!}}{\left(\sum_{k=0}^{m-1} \frac{(m\rho)^k}{k!}\right) + \frac{(m\rho)^m}{m!\,(1-\rho)}}, n \leq m$$

Resultado de a)

$$N_O = 0\pi_0 + 1\pi_1 + 2\pi_2 + 3\pi_3 + 4\,\boldsymbol{P_Q}$$

$$N_O = \frac{\frac{4 \times 0.75}{1!} + 2 \times \frac{(4 \times 0.75)^2}{2!} + 3 \times \frac{(4 \times 0.75)^3}{3!}}{1 + \frac{4 \times 0.75}{1!} + \frac{(4 \times 0.75)^2}{2!} + \frac{(4 \times 0.75)^3}{3!} + \frac{(4 \times 0.75)^4}{4! \times (1 - 0.75)}} + 4 \times 0.5094$$

$$N_O = 3.0$$

R: Em média, estão 3.0 operadores ocupados

Exemplo 6

Um servidor de *Call Center* tem *m* operadores e prevê uma taxa de chegada de λ pedidos por hora. Cada chamada tem uma duração exponencial de 3 minutos de média.

P_Q : probabilidade de todos os operadores estarem ocupados

W_Q : tempo médio dos clientes em espera

λ (hora^{-1})	*m*	P_Q	W_Q (seg.)
750	50	3.41%	0.49
800	50	8.70%	1.57
850	50	18.97%	4.55
900	50	36.39%	13.10
950	50	62.91%	45.29
1500	100	0.37%	0.03
1600	100	1.97%	0.18
1700	100	7.49%	0.90
1800	100	21.69%	3.90
1900	100	50.64%	18.23

Existem ganhos de escala: 2 vezes mais operadores atendem o dobro da taxa de chegada de pedidos com melhor desempenho.

Tipos de serviços mistos
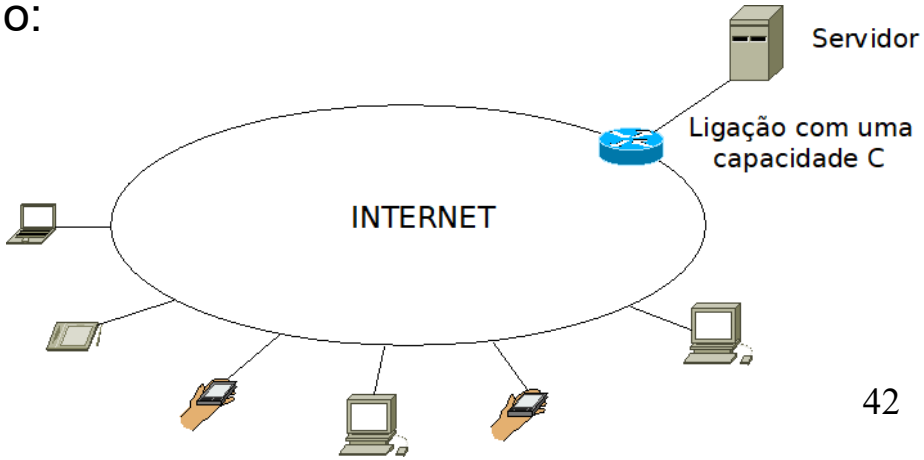
- Exemplo: serviços de música online (Spotify, Apple Music, YouTube Music, etc.) que permitem ouvir e partilhar músicas online
- O tempo de serviço é caracterizado pela duração da sessão do utilizador (i.e., desde que ele se liga até que se desliga do serviço)
- Durante cada sessão, há a transmissão de um débito binário variável (alternando envio de músicas e tempos entre músicas)
- Como o débito binário da música é muito menor que dos filmes, a capacidade da ligação *C* e a capacidade de processamento (CPU, RAM) podem ser ambas limitativas
- O desempenho do serviço pode ser modelado por um sistema *M*/*M*/*m*/*m* em que *m* é escolhido como o menor entre o número máximo de sessões permitido:
  - pela capacidade de processamento do servidor
  - pala capacidade *C* da ligação de rede do servidor